Etudiants : Cazeres Mathieu (22200082), Martin-Chantereau Etienne (21909526), Moreaux Victor (22200010), Poiret Valentin (21609227)

# Notebook pour le cas de classification True vs False vs Other vs Mixture.

Le Notebook contient 3 parties :

- Visualisation des données
- Classification de base avec les données 'train' et 'test'
- Classification avec nouvelles données basé sur les texts
- Classification avec nouvelles données basé sur les titres
- Double classification

Chargement des données des fonctions utilisées dans le notebook

```
import sys
from google.colab import drive
drive.mount('/content/drive')
my local drive =
"/content/drive/MyDrive/projet ML/Projet MachineLearning"
# fonctions utilities (affichage, confusion, etc.)
svs.path.append(my_local_drive)
# Se positionner sur le répertoire associé
%cd $my local drive
%pwd
import warnings
warnings.filterwarnings("ignore", category=FutureWarning)
!pip install learn
# fonctions utilities (affichage, confusion, etc.)
from Fonction.MyNLPUtilities import *
from Fonction.myFonction import *
from Fonction.AllModels import *
from Fonction.visualisation import *
# Ce code en commentaire permet de concatener les données en un seul
dataframe
# Init train = pd.read csv('./Data brut/HAI817 Projet train.csv',
sep=",\overline{"})
# Init test = pd.read csv('./Data brut/HAI817 Projet test.csv',
sep=",")
# Init Alle = pd.read csv('./Data brut/data allemand all.csv',
```

```
sep=",")
# data brute = pd.concat([Init train, Init test, Init Alle],
ignore\ index = True)
# for i in range(0,len(data brute['our rating'])):
# if data brute['our rating'][i] == 'Other':
       data brute['our rating'][i] = 'other'
# data brute = data brute.drop duplicates()
# print(data brute['our rating'].value counts())
# Ce code permet de générer des sous-échantillons équilibré
# data equilibre = balanceSample(data brute, 210,
["false", "true", "mixture", "other"])
# print(data equilibre['our rating'].value counts())
# data equilibre.to csv('./Data equilibre/MyData Sprint2.csv',
sep=',', index=False)
Mounted at /content/drive
/content/drive/MyDrive/projet ML/Projet MachineLearning
Looking in indexes: https://pypi.org/simple, https://us-
python.pkg.dev/colab-wheels/public/simple/
Collecting learn
  Downloading learn-1.0.0.zip (818 bytes)
  Preparing metadata (setup.py) ... e=learn-1.0.0-py3-none-any.whl
size=1258
sha256=93a1562c572058af358a578852727a7cb567c2fe5d9edfc24ad0b366f5440cd
  Stored in directory:
/root/.cache/pip/wheels/15/8c/c4/db38629e6d3d6cdc65cca1dd26334ad5a0aef
4f01d67be09c7
Successfully built learn
Installing collected packages: learn
Successfully installed learn-1.0.0
[nltk data] Downloading package wordnet to /root/nltk data...
[nltk data] Downloading package stopwords to /root/nltk data...
[nltk data]
              Unzipping corpora/stopwords.zip.
[nltk data] Downloading package punkt to /root/nltk data...
[nltk data]
              Unzipping tokenizers/punkt.zip.
[nltk data] Downloading package wordnet to /root/nltk data...
[nltk_data]
              Package wordnet is already up-to-date!
[nltk data] Downloading package stopwords to /root/nltk data...
[nltk data] Package stopwords is already up-to-date!
```

```
[nltk_data] Downloading package punkt to /root/nltk_data...
[nltk_data] Package punkt is already up-to-date!
```

### Visualisation des données

## L'analyse T-SNE (t-Distributed Stochastic Neighbor Embedding)

```
myTSNE_2d_3d(X_train,y_train)
```

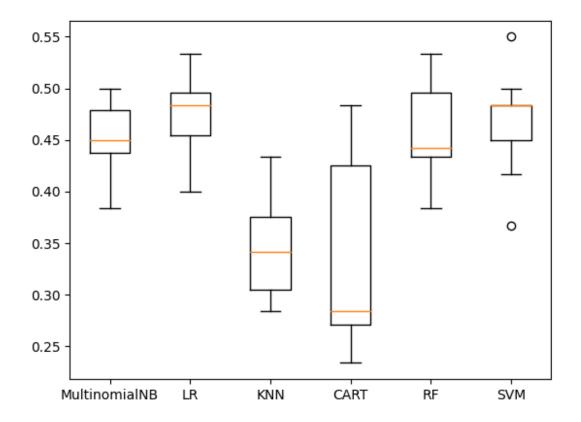
La proximité des centroïdes des différentes classes dans l'espace créé par T-SNE peut annoncer une certaine difficulté pour la classification. En effet, si les différentes classes sont très proches les unes des autres, cela peut rendre difficile pour un algorithme de classification de les distinguer avec précision.

# Sprint 1 : Classification avec les données 'train' et 'test'.

```
mySample = pd.read_csv('./Data_equilibre/MyData_Sprint1.csv', sep=",")
print(mySample['our rating'].value_counts())
```

```
X train = mySample['text']
y_train = mySample['our rating']
false
          150
true
          150
          150
mixture
          150
other
Name: our rating, dtype: int64
testAllModel(X train,y train,3)
[nltk data] Downloading package omw-1.4 to /root/nltk_data...
Evaluation de MultinomialNB
MultinomialNB : 0.452 (0.037) in 0.910 s
Evaluation de LR
LR: 0.472 (0.042) in 25.055 s
Evaluation de KNN
KNN: 0.342 (0.046) in 4.372 s
Evaluation de CART
CART: 0.338 (0.091) in 10.399 s
Evaluation de RF
RF: 0.457 (0.044) in 17.574 s
Evaluation de SVM
SVM : 0.467 (0.047) in 94.850 s
Le meilleur resultat :
Classifier: LR accuracy: 0.472 (0.042) en 25.055
Tous les résultats :
Classifier :
             LR accuracy: 0.472 (0.042)
                                           en 25.055
                                                       S
             SVM accuracy: 0.467 (0.047)
Classifier :
                                            en 94.850
                                                        S
Classifier:
             RF accuracy: 0.457 (0.044) en 17.574
                                                       S
             MultinomialNB accuracy: 0.452 (0.037)
Classifier :
                                                      en 0.910
Classifier :
             KNN accuracy: 0.342 (0.046) en 4.372
             CART accuracy: 0.338 (0.091)
Classifier:
                                             en 10.399
```

# Comparaison des algorithmes



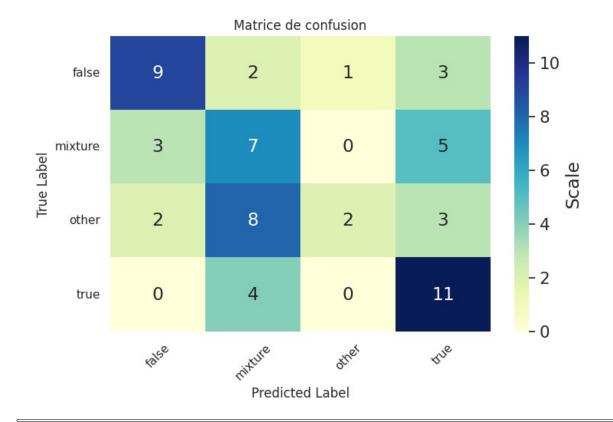
-> Les modèles SVM, LR, RF et MNB sont les plus performants. Pour chacun de ces modèles, nous allons chercher les meilleurs paramètrages de prétraitement et les meilleurs paramètrages du modèle.

#### Modèle SVM (Support Vector Machine)

```
testSVC(X_train, y_train,3,"./Data_parametrage/data_svm_mathieu_0")
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'svm']
parameters :
{'cleaner__removedigit': [True, False], 'cleaner__getlemmatisation':
[True, False], 'tfidf__stop_words': ['english', None],
'tfidf__lowercase': [True, False], 'svm__C': [0.001, 0.01, 0.1, 1,
10], 'svm__gamma': [0.001, 0.01, 0.1, 1], 'svm__kernel': ['linear',
'rbf', 'poly', 'sigmoid']}
Fitting 3 folds for each of 1280 candidates, totalling 3840 fits
[nltk_data] Downloading package omw-1.4 to /root/nltk_data...
[nltk_data] Package omw-1.4 is already up-to-date!
```

```
réalisé en 748.152 s
Meilleur résultat : 0.472
Ensemble des meilleurs paramètres :
     cleaner getlemmatisation: False
     cleaner removedigit: False
     svm_ C: 10
     svm gamma: 1
     svm kernel: 'rbf'
     tfidf lowercase: True
     tfidf stop words: None
Les premiers résultats :
       cleaner getlemmatisation cleaner removedigit svm C
svm gamma \
1269
                          False
                                                False
                                                         10.0
1.00
631
                           True
                                                False
                                                         10.0
1.00
                          False
                                                False
                                                         10.0
1261
0.10
1169
                          False
                                                False
                                                          1.0
0.01
295
                           True
                                                 True
                                                         10.0
0.10
     svm_kernel tfidf_lowercase tfidf_stop_words
                                                      accuracy
             rbf
1269
                              True
                                                None
                                                      0.471667
                             False
631
             rbf
                                                None 0.468333
1261
         sigmoid
                              True
                                                None 0.465000
         linear
                              True
                                                None 0.465000
1169
295
             rbf
                             False
                                                None 0.465000
Enregistrement du modèle
from sklearn.model selection import train test split
import pickle
# Création d'un jeu d'apprentissage et de test
trainsize=0.9
testsize= 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
train,
train size=trainsize, random state=seed, test size=testsize, stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=False,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words=None)),
```

```
('svm', SVC(C=10, gamma=1, kernel='rbf'))
1)
pipeline.fit(train_title,train_note)
filename='./Modele/TruevsFalsevsMixturevsOther/Svm final 0.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Svm final 0.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer()), ('tfidf',
TfidfVectorizer()),
                ('svm', SVC(C=10, gamma=1))])
Accuracy: 0.483
Classification Report
              precision
                           recall f1-score
                                              support
                          0.60000
       false
                0.64286
                                    0.62069
                                                    15
     mixture
                0.33333
                          0.46667
                                    0.38889
                                                    15
                0.66667
                          0.13333
                                    0.22222
                                                    15
       other
        true
                0.50000
                          0.73333
                                    0.59459
                                                    15
                                    0.48333
                                                    60
    accuracy
                                                    60
   macro avg
                0.53571
                          0.48333
                                    0.45660
weighted avg
                0.53571
                          0.48333
                                    0.45660
                                                    60
```



#### Modèle RFC (RandomForestClassifier)

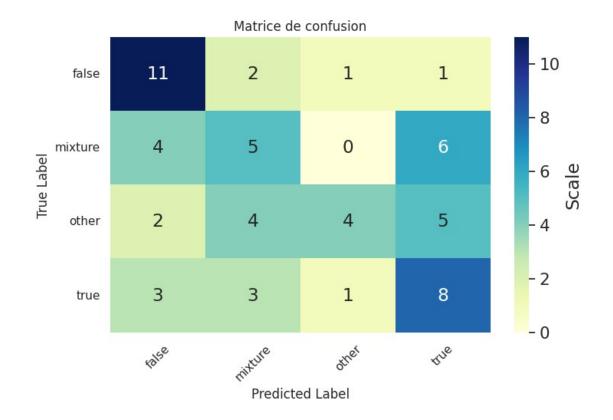
```
testRFC(X train, y train, 3, "./Data parametrage/data rfc mathieu 0")
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'rfc']
parameters :
{'cleaner__removedigit': [True, False], 'cleaner__getlemmatisation':
[True, False], 'tfidf stop words': ['english', None],
'tfidf__lowercase': [True, False], 'rfc__n_estimators': [500, 1200],
'rfc__max_depth': [25, 30], 'rfc__min_samples_split': [5, 10, 15],
'rfc min samples leaf': [1, 2]}
Fitting 3 folds for each of 384 candidates, totalling 1152 fits
réalisé en 354.906 s
Meilleur résultat : 0.483
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
     cleaner removedigit: True
     rfc max depth: 30
     rfc min samples leaf: 1
     rfc min samples split: 5
     rfc n estimators: 500
     tfidf__lowercase: True
```

tfidf\_\_stop\_words: None

Les premiers résultats : cleanerremovedigit rfcmax_depth							
\ 267	False	True	30				
241	False	True	30				
199	False	True	25				
349	False	False	30				
249	False	True	30				
rfcmin_samples_leaf							
\ 267	2	5	500				
241	1	5	500				
199	1	5	1200				
349	1	10	1200				
249	1	10	500				
267 241 199 349 249	tfidflowercase tfidfstop_words False None True None False None True None True None	0.483333 0.483333 0.476667					
<pre>import pickle from sklearn.ensemble import RandomForestClassifier from sklearn.model_selection import train_test_split # Création d'un jeu d'apprentissage et de test trainsize=0.9 testsize= 0.1 seed=30 train_title,test_title,train_note,test_note=train_test_split(X_train,y_train, train_size=trainsize,random_state=seed,test_size=testsize,stratify=y_train) # stratified = yes</pre>							

## double classification a regarder

```
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=False, stop words=None)),
    ('rfc', RandomForestClassifier(max depth=30,min samples leaf=2,
min samples split=5, n estimators=500))
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Rfc final 0.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Rfc final 0.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer(removedigit=True)),
                ('tfidf', TfidfVectorizer(lowercase=False)),
                 RandomForestClassifier(max depth=30,
min samples leaf=2,
                                        min samples split=5,
                                        n estimators=500))])
Accuracy: 0.467
Classification Report
              precision
                           recall f1-score
                                              support
                                                   15
       false
                0.55000
                          0.73333
                                    0.62857
                          0.33333
                                    0.34483
                                                   15
     mixture
                0.35714
       other
                0.66667
                          0.26667
                                    0.38095
                                                   15
        true
                0.40000
                          0.53333
                                    0.45714
                                                   15
                                    0.46667
                                                   60
    accuracy
                0.49345
                          0.46667
                                    0.45287
                                                   60
   macro avg
                          0.46667
weighted avg
                0.49345
                                    0.45287
                                                   60
```

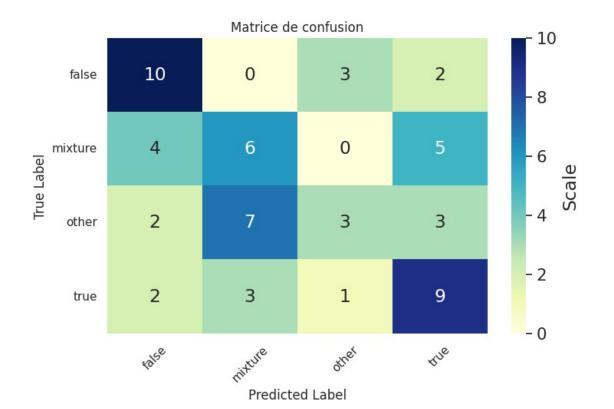


#### Modèle LR (LogisticRegression)

```
testLR(X train, y train, 3, './Data parametrage/data lr mathieu 0')
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'lr']
parameters :
{'cleaner__removedigit': [True, False], 'cleaner__getlemmatisation':
[True, False], 'tfidf stop words': ['english', None],
'tfidf_lowercase': [True, False], 'lr_solver': ['newton-cg',
'lbfgs', 'liblinear'], 'lr__penalty': ['l2'], 'lr__C': [100, 10, 1.0,
0.1, 0.01]}
Fitting 3 folds for each of 240 candidates, totalling 720 fits
réalisé en 130.970 s
Meilleur résultat : 0.470
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: True
     cleaner removedigit: True
     lr C: \overline{10}
     lr__penalty: 'l2'
lr__solver: 'liblinear'
     tfidf lowercase: False
     tfidf stop words: None
```

```
Les premiers résultats :
      cleaner getlemmatisation cleaner removedigit lr C
lr penalty \
23
                          True
                                                True
                                                        10.0
12
83
                          True
                                               False
                                                        10.0
12
199
                         False
                                               False
                                                        10.0
12
195
                         False
                                               False
                                                       10.0
12
11
                          True
                                                True
                                                      100.0
12
    lr solver tfidf lowercase tfidf stop words accuracy
23
    liblinear
                           False
                                              None
                                                    0.470000
     liblinear
                           False
                                              None 0.470000
83
199
         lbfas
                           False
                                              None 0.466667
195
                           False
                                              None 0.466667
    newton-cq
11
     liblinear
                           False
                                              None 0.466667
import pickle
from sklearn.linear model import LogisticRegression
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9
testsize= 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
train size=trainsize, random state=seed, test size=testsize, stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=True)),
    ("tfidf", TfidfVectorizer(lowercase=False, stop words=None)),
    ('lr', LogisticRegression(C=10,penalty='l2', solver='liblinear'))
1)
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Lr final 0.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
```

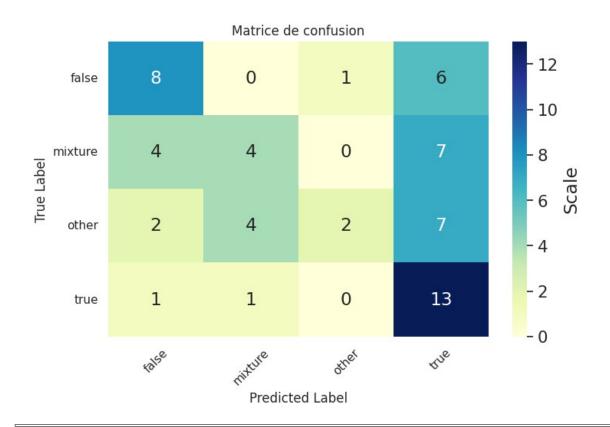
```
# test
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Lr_final_0.pkl
Chargement du modèle
Pipeline(steps=[('cleaner',
                 TextNormalizer(getlemmatisation=True,
removedigit=True)),
                 ('tfidf', TfidfVectorizer(lowercase=False)),
                 ('lr', LogisticRegression(C=10, solver='liblinear'))])
Accuracy: 0.467
Classification Report
              precision
                            recall
                                    f1-score
                                                support
       false
                0.55556
                           0.66667
                                     0.60606
                                                     15
                0.37500
                           0.40000
                                     0.38710
                                                     15
     mixture
                0.42857
                           0.20000
                                     0.27273
                                                     15
       other
        true
                0.47368
                           0.60000
                                     0.52941
                                                     15
                                     0.46667
                                                     60
    accuracy
   macro avg
                0.45820
                           0.46667
                                     0.44882
                                                     60
weighted avg
                0.45820
                           0.46667
                                     0.44882
                                                     60
```



```
testMNB(X train, y train, 3, './Data parametrage/data mnb mathieu 0')
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'mnb']
parameters :
{'cleaner__removedigit': [True, False], 'cleaner__getlemmatisation':
[True, False], 'tfidf stop words': ['english', None],
'tfidf lowercase': [True, False], 'mnb alpha': array([0.5, 0.7, 0.9,
1.1, 1.3, 1.5]), 'mnb fit prior': [True, False], 'mnb force alpha':
[True, False]}
Fitting 3 folds for each of 384 candidates, totalling 1152 fits
réalisé en 181.284 s
Meilleur résultat : 0.468
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
     cleaner removedigit: False
     mnb alpha: 0.5
     mnb__fit_prior: True
     mnb force alpha: True
     tfidf__lowercase: True
     tfidf stop words: None
Les premiers résultats :
      cleaner getlemmatisation cleaner removedigit mnb alpha \
289
                         False
                                               False
                                                             0.5
301
                         False
                                               False
                                                             0.5
297
                         False
                                                             0.5
                                               False
293
                                                             0.5
                         False
                                               False
252
                         False
                                                True
                                                             1.1
     mnb fit prior mnb force alpha tfidf lowercase
tfidf stop words \
289
               True
                                 True
                                                   True
None
              False
                                False
301
                                                   True
None
297
              False
                                 True
                                                   True
None
293
               True
                                False
                                                   True
None
252
              False
                                False
                                                   True
english
```

```
289 0.468333
301 0.468333
297 0.468333
293 0.468333
252 0.466667
import pickle
from sklearn.naive bayes import MultinomialNB
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9
testsize= 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
train,
train size=trainsize, random state=seed, test size=testsize, stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=False,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words=None)),
    ('mnb', MultinomialNB(alpha=0.5, fit_prior=True,
force alpha=True))
])
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Mnb final 0.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Mnb final 0.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer()), ('tfidf',
TfidfVectorizer()),
                ('mnb', MultinomialNB(alpha=0.5, force alpha=True))])
Accuracy: 0.450
Classification Report
              precision
                           recall f1-score
                                               support
       false
                0.53333
                          0.53333
                                                    15
                                    0.53333
```

mixture	0.44444	0.26667	0.33333	15
other	0.66667	0.13333	0.22222	15
true	0.39394	0.86667	0.54167	15
accuracy			0.45000	60
macro avg	0.50960	0.45000	0.40764	60
weighted avg	0.50960	0.45000	0.40764	60



Sprint 2 : Classification avec nouvelles données basé sur les texts

```
mySample = pd.read_csv('./Data_equilibre/MyData_Sprintlet2.csv',
sep=",")
print(mySample['our rating'].value_counts())
X_train = mySample['text']
y_train = mySample['our rating']
```

```
false
           210
true
           210
mixture
           210
           210
other
```

Name: our rating, dtype: int64

Etape 1 : tester plusieurs modèles différents afin d'identifier 2 ou 3 modèles a ajuster

testAllModel(X train,y train,3)

[nltk data] Downloading package omw-1.4 to /root/nltk data...

Evaluation de MultinomialNB

MultinomialNB : 0.487 (0.057) in 1.100 s

Evaluation de LR

LR: 0.532 (0.053) in 33.233 s

Evaluation de KNN

KNN : 0.411 (0.046) in 2.834 s

Evaluation de CART

CART: 0.437 (0.057) in 17.225 s

Evaluation de RF

RF: 0.487 (0.048) in 22.126 s

Evaluation de SVM

SVM : 0.543 (0.051) in 88.671 s

Le meilleur resultat :

Classifier: SVM accuracy: 0.543 (0.051) en 88.671

Tous les résultats :

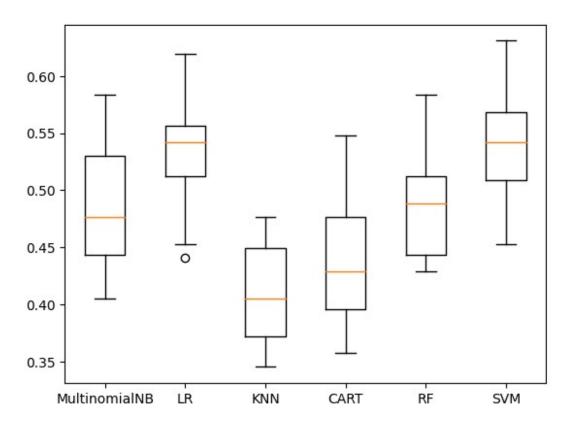
Classifier: SVM accuracy: 0.543 (0.051) en 88.671 S S

Classifier : LR accuracy: 0.532 (0.053) en 33.233

Classifier: MultinomialNB accuracy: 0.487 (0.057)en 1.100 S

Classifier : RF accuracy: 0.487 (0.048) en 22.126 accuracy : 0.437 (0.057) Classifier : CART en 17.225 S Classifier: KNN accuracy: 0.411 (0.046) en 2.834

# Comparaison des algorithmes



-> Les modèles SVM, LR, RF et MNB sont les plus performants. Pour chacun de ces modèles, nous allons chercher les meilleurs paramètrages de prétraitement et les meilleurs paramètrages du modèle.

#### Modèle SVM (Support Vector Machine)

```
testSVC(X_train, y_train,3,"./Data_parametrage/data_svm_mathieu_1")
[nltk_data] Downloading package omw-1.4 to /root/nltk_data...
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'svm']
parameters :
{'cleaner__removedigit': [True, False], 'cleaner__getlemmatisation':
[True, False], 'tfidf__stop_words': ['english', None],
'tfidf__lowercase': [True, False], 'svm__C': [0.001, 0.01, 0.1, 1,
10], 'svm__gamma': [0.001, 0.01, 0.1, 1], 'svm__kernel': ['linear',
'rbf', 'poly', 'sigmoid']}
Fitting 3 folds for each of 1280 candidates, totalling 3840 fits
réalisé en 1045.372 s
```

```
Meilleur résultat : 0.540
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
     cleaner removedigit: False
     svm C: 10
     svm__gamma: 0.1
     svm kernel: 'rbf'
     tfidf lowercase: False
     tfidf stop words: None
Les premiers résultats :
       cleaner getlemmatisation cleaner removedigit svm C
s∨m gamma \
                          False
                                                False
1255
                                                         10.0
0.10
                          False
                                                         10.0
935
                                                 True
0.10
620
                           True
                                                False
                                                         10.0
0.10
528
                           True
                                                False
                                                          1.0
0.01
560
                                                False
                                                          1.0
                           True
1.00
     svm_kernel tfidf_lowercase tfidf_stop_words accuracy
1255
             rbf
                                                None 0.540476
                             False
935
             rbf
                             False
                                                None 0.534524
620
         sigmoid
                              True
                                            english 0.532143
528
         linear
                              True
                                             english 0.532143
560
         linear
                              True
                                             english 0.532143
Affichage des points de rupture sur la courbe et de la proportion de certains paramètres
pour chaque segment :
from matplotlib import patches
from numpy import NaN
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
!pip install ruptures
import ruptures as rpt
# Charger les données
data = pd.read_csv('./Data_parametrage/data svm mathieu 1.csv')
data.fillna('vide', inplace=True)
# Sélectionner les colonnes à analyser
y colonne = 'accuracy'
# Choix du modèle pour trouver les points de ruptures
```

```
signal = data[y colonne].values
model = "l2"
algo = rpt.Window(width=40, model=model, jump=1).fit(signal)
result = algo.predict(n bkps=2)
fig, ax = plt.subplots(figsize=(10, 5))
# Choix des paramètre a garder pour l'analyse de répartition
# params =
["cleaner getlemmatisation", "cleaner removedigit", 'tfidf lowercase'
,'tfidf stop words']
params = ['svm_C','svm_gamma','svm_kernel']
# Creation d'un dataFrame pour enregistrer les paramètre de chaque
modèle
l = []
for param in params:
  p = data[param].value counts(normalize=True)
  for i in range(len(p)):
    x = p.index.tolist()[i]
    l.append(str(param)+"="+str(x))
mydf = pd.DataFrame(columns=l,index=[0, 1, 2])
# Ajouter tout les point qui corresponde a l'accuracy
ax.plot(data.index, data[y colonne], 'x', color='black')
my row=[]
for i, (start, end) in enumerate(zip([0] + result, result +
[len(signal)])):
    segment = data.iloc[start:end]
    # Calcul de la proportion de chaque parametre dans chaque sous
groupe
    param props = []
    for param in params:
        param value counts =
segment[param].value counts(normalize=True)
        param value props = [f"{count*100:.2f}%" for count in
param_value_counts]
        param_value_legend = " / ".join([f"{param}={param_value}]
({param value props[j]}) " for j, param value in
enumerate(param value counts.index)])
        param props.append(param value legend)
        # Pour creer mon dataframe avec les paramètres
        for j, param value in enumerate(param value counts.index):
          k=str(param)+"="+str(param_value)
          param value counts df = param value counts.reset index()
          param value counts df =
```

```
param value counts df.rename(columns={param: 'Parametre', 0:
'Pourcentage'})
          mydf.loc[i][k]=param value counts df.loc[j, 'Parametre']
    # ioindre la legende
    segment_legend = " / ".join(param_props)
    # ajouter la droite de regression
    sns.regplot(x=segment.index, y=y colonne, data=segment, ax=ax,
color=f'C{i+1}',
                label=f'Segment {i+1}', scatter=False)
    # afficher le début et la fin de chaque segment
    if(start != len(data[v colonne])):
        ax.text(start, segment[y colonne].min(), f'start: {start}',
fontsize=8)
        if start not in my row:
            my_row.append(start)
    if(end-1 != len(data[y colonne])):
        ax.text(end, segment[y_colonne].max(), f'end: {end-1}',
fontsize=8)
        if end-1 not in my row:
            my row.append(end-1)
# Mise en page de la figure
ax.set xlabel('Index')
ax.set_ylabel(y_colonne)
ax.legend(loc='lower center', ncol=1)
plt.show()
fig.savefig('data svm mathieu 1 tot.png', dpi=300,
bbox inches='tight')
# créer le graphique
fig, ax = plt.subplots(figsize=(8, 6))
mydf.plot(kind='bar', ax=ax)
# ajouter des étiquettes
ax.set xlabel('Segment')
ax.set ylabel('Proportion des paramètres')
legend = ax.legend(loc='center left', bbox_to_anchor=(1.0, 0.5))
# afficher le graphique
plt.show()
Looking in indexes: https://pypi.org/simple, https://us-
python.pkg.dev/colab-wheels/public/simple/
Collecting ruptures
  Downloading ruptures-1.1.7-cp39-cp39-
manylinux 2 17 x86 64.manylinux2014 x86 64.whl (1.0 MB)
```

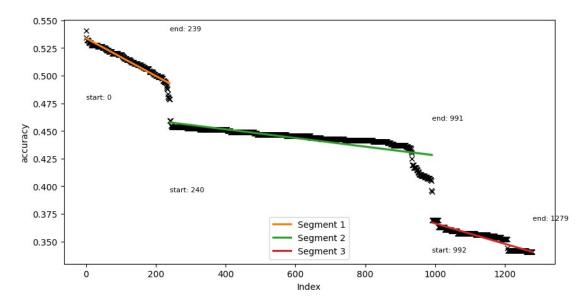
0:00:00

ent already satisfied: numpy in /usr/local/lib/python3.9/dist-packages
(from ruptures) (1.24.3)

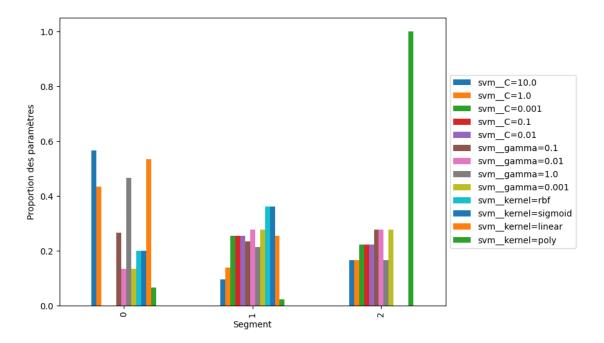
Requirement already satisfied: scipy in /usr/local/lib/python3.9/dist-packages (from ruptures) (1.10.1)

Installing collected packages: ruptures Successfully installed ruptures-1.1.7

WARNING:matplotlib.text:posx and posy should be finite values WARNING:matplotlib.text:posx and posy should be finite values



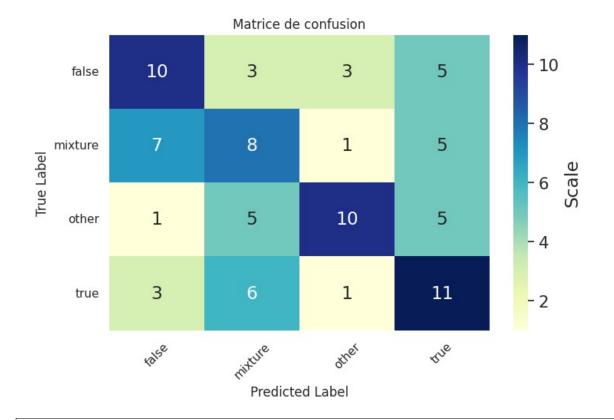
WARNING:matplotlib.text:posx and posy should be finite values WARNING:matplotlib.text:posx and posy should be finite values



Enregistrement du modele SVC avec les meilleurs paramètres

```
from sklearn.model selection import train test split
import pickle
# Création d'un jeu d'apprentissage et de test
trainsize=0.9
testsize= 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
__train size=trainsize,random_state=seed,test_size=testsize,stratify=y_t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=False,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=False, stop_words=None)),
    ('svm', SVC(C=10, gamma=0.1, kernel='rbf'))
1)
pipeline.fit(train_title,train_note)
filename='./Modele/TruevsFalsevsMixturevsOther/Svm final 1.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
```

```
print (clf_loaded)
# test
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test_note,y_pred)
Sauvegarde du modèle dans ./Modele/final/Svm_final_1.pkl
Chargement du modèle
('svm', SVC(C=10, gamma=0.1))])
Accuracy: 0.464
Classification Report
            precision
                        recall f1-score
                                         support
              0.47619
                       0.47619
                                0.47619
                                             21
      false
    mixture
              0.36364
                       0.38095
                                0.37209
                                             21
      other
true
                                             21
              0.66667
                       0.47619
                                0.55556
              0.42308
                       0.52381
                                0.46809
                                             21
                                             84
                                0.46429
   accuracy
            0.48239
                       0.46429
                                0.46798
                                             84
  macro avg
weighted avg
              0.48239
                       0.46429
                                0.46798
                                             84
```



#### Modèle RFC (RandomForestClassifier)

```
testRFC(X train, y train, 3, "./Data parametrage/data rfc mathieu 1")
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'rfc']
parameters :
{'cleaner__removedigit': [True, False], 'cleaner__getlemmatisation':
[True, False], 'tfidf stop words': ['english', None],
'tfidf_lowercase': [True, False], 'rfc_n_estimators': [500, 1200],
'rfc__max_depth': [25, 30], 'rfc__min_samples_split': [5, 10, 15],
'rfc min samples leaf': [1, 2]}
Fitting 3 folds for each of 384 candidates, totalling 1152 fits
réalisé en 506.813 s
Meilleur résultat : 0.517
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
     cleaner removedigit: False
     rfc max depth: 25
     rfc min_samples_leaf: 1
     rfc min samples split: 15
     rfc n estimators: 500
     tfidf lowercase: False
```

tfidf\_\_stop\_words: None

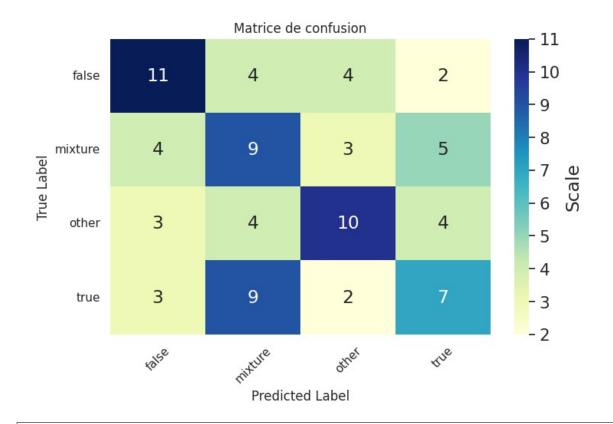
	<pre>premiers résultats :   cleanergetlemmatisation</pre>	cleanerremovedigi	.t rfcmax_depth				
307	False	False	25				
184	True	False	9 30				
336	False	False	9 30				
8	True	True	25				
382	False	False	9 30				
\	rfcmin_samples_leaf rfc_		rfcn_estimators				
307	1	15	500				
184	2	15	500				
336	1	5	500				
8	1	10	500				
382	2	15	1200				
307 184 336 8 382	tfidflowercase tfidfsto False True True True False	op_words accuracy None 0.516667 english 0.516667 english 0.515476 english 0.514286 english 0.514286					
Enregistrement du modele RFC avec les meilleurs paramètres							
<pre>import pickle from sklearn.ensemble import RandomForestClassifier from sklearn.model_selection import train_test_split # Création d'un jeu d'apprentissage et de test trainsize=0.9 testsize= 0.1 seed=30</pre>							

train\_title,test\_title,train\_note,test\_note=train\_test\_split(X\_train,y

\_train, train\_size=trainsize,random\_state=seed,test\_size=testsize,stratify=y\_t

rain) # stratified = yes

```
## double classification a regarder
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=False,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=False, stop words='english')),
    ('rfc', RandomForestClassifier(max depth=30,min samples leaf=2,
min samples split=10, n estimators=500))
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Rfc final 1.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Rfc final 1.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer()),
                ('tfidf',
                 TfidfVectorizer(lowercase=False,
stop words='english')),
                ('rfc',
                 RandomForestClassifier(max depth=30,
min samples leaf=2,
                                        min samples split=10,
                                        n estimators=500))])
Accuracy: 0.440
Classification Report
                          recall f1-score
              precision
                                              support
                0.52381
                          0.52381
                                    0.52381
                                                   21
       false
                                                   21
     mixture
                0.34615
                          0.42857
                                    0.38298
       other
                0.52632
                          0.47619
                                    0.50000
                                                   21
        true
                0.38889
                          0.33333
                                    0.35897
                                                   21
                                    0.44048
                                                   84
    accuracy
              0.44629
                          0.44048
                                    0.44144
                                                   84
   macro avq
weighted avg
                0.44629
                          0.44048
                                    0.44144
                                                   84
```

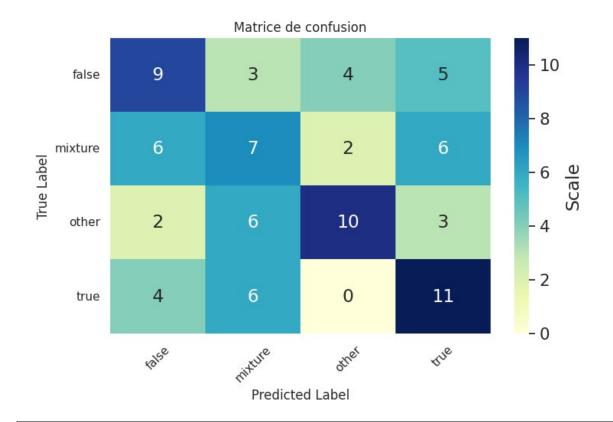


#### Modèle LR (LogisticRegression)

```
testLR(X train, y train, 3, './Data parametrage/data lr mathieu 1')
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'lr']
parameters :
{'cleaner__removedigit': [True, False], 'cleaner__getlemmatisation':
[True, False], 'tfidf stop words': ['english', None],
'tfidf_lowercase': [True, False], 'lr_solver': ['newton-cg',
'lbfgs', 'liblinear'], 'lr__penalty': ['l2'], 'lr__C': [100, 10, 1.0,
0.1, 0.01]}
Fitting 3 folds for each of 240 candidates, totalling 720 fits
réalisé en 193.205 s
Meilleur résultat : 0.531
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
     cleaner removedigit: True
     lr C: \overline{100}
     lr__penalty: 'l2'
lr__solver: 'lbfgs'
     tfidf lowercase: True
     tfidf stop words: None
```

```
Les premiers résultats :
      cleaner getlemmatisation cleaner removedigit lr C
lr penalty \
129
                         False
                                                True
                                                      100.0
12
125
                         False
                                                True
                                                      100.0
12
                         False
121
                                                True
                                                      100.0
12
197
                         False
                                               False
                                                       10.0
12
193
                         False
                                               False
                                                       10.0
12
    lr solver tfidf lowercase tfidf stop words accuracy
129 liblinear
                            True
                                              None
                                                    0.530952
125
         lbfas
                            True
                                              None 0.530952
121 newton-ca
                            True
                                              None 0.529762
197
                            True
                                              None 0.529762
         lbfgs
193 newton-cg
                            True
                                              None 0.529762
/usr/local/lib/python3.9/dist-packages/sklearn/linear model/
_logistic.py:458: ConvergenceWarning: lbfqs failed to converge
(status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
Increase the number of iterations (max iter) or scale the data as
shown in:
    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
https://scikit-learn.org/stable/modules/linear model.html#logistic-
regression
  n iter i = check optimize result(
Enregistrement du modele LR avec les meilleurs paramètres
import pickle
from sklearn.linear model import LogisticRegression
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9
testsize = 0.1
seed=30
train title,test title,train note,test note=train_test_split(X_train,y
train size=trainsize, random state=seed, test size=testsize, stratify=y t
rain)
```

```
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=False, stop words=None)),
    ('lr', LogisticRegression(C=100,penalty='l2', solver='liblinear'))
pipeline.fit(train title.train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Lr final 1.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test_note,y_pred)
Sauvegarde du modèle dans ./Modele/final/Lr final 1.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer(removedigit=True)),
                ('tfidf', TfidfVectorizer(lowercase=False)),
                ('lr', LogisticRegression(C=100,
solver='liblinear'))])
Accuracy: 0.440
Classification Report
              precision
                           recall f1-score
                                              support
       false
                0.42857
                          0.42857
                                    0.42857
                                                   21
                0.31818
                          0.33333
                                    0.32558
                                                   21
     mixture
                                                   21
       other
                0.62500
                          0.47619
                                    0.54054
                0.44000
                          0.52381
                                                   21
        true
                                    0.47826
    accuracy
                                    0.44048
                                                   84
                          0.44048
                                    0.44324
                                                   84
                0.45294
   macro avq
                0.45294
                          0.44048
                                    0.44324
                                                   84
weighted avg
```



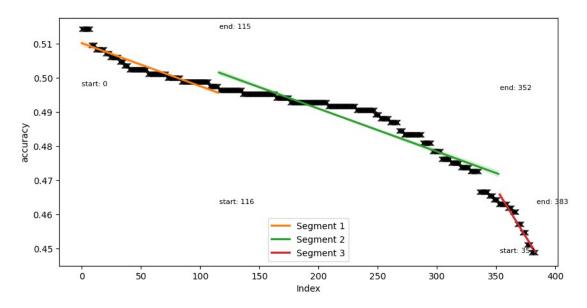
#### Modèle MNB (MultinomialNB)

```
testMNB(X train, y train, 3, './Data parametrage/data mnb mathieu 1')
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'mnb']
parameters :
{'cleaner__removedigit': [True, False], 'cleaner__getlemmatisation':
[True, False], 'tfidf__stop_words': ['english', None],
'tfidf_lowercase': [True, False], 'mnb_alpha': array([0.5, 0.7, 0.9,
1.1, 1.3, 1.5]), 'mnb__fit_prior': [True, False], 'mnb__force_alpha':
[True, False]}
Fitting 3 folds for each of 384 candidates, totalling 1152 fits
réalisé en 279.456 s
Meilleur résultat : 0.514
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
     cleaner removedigit: True
     mnb alpha: 0.5
     mnb__fit_prior: True
     mnb force alpha: True
     tfidf lowercase: False
     tfidf stop words: 'english'
```

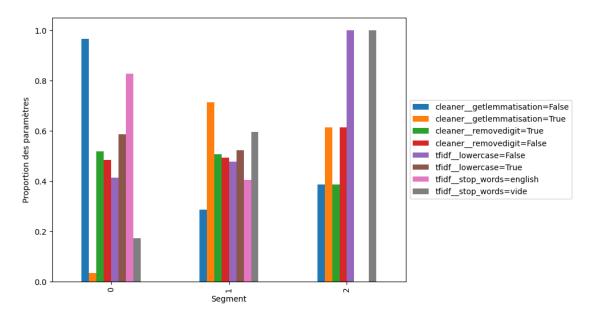
```
Les premiers résultats :
      cleaner__getlemmatisation cleaner__removedigit mnb__alpha \
194
                                                True
                                                              0.5
                         False
206
                         False
                                                True
                                                              0.5
298
                         False
                                                False
                                                              0.5
294
                         False
                                                False
                                                              0.5
290
                                                              0.5
                         False
                                               False
     mnb__fit_prior mnb__force_alpha tfidf__lowercase
tfidf stop words \
194
               True
                                 True
                                                  False
english
206
              False
                                False
                                                  False
enalish
298
              False
                                 True
                                                  False
english
294
               True
                                False
                                                  False
enalish
290
               True
                                 True
                                                  False
english
     accuracy
194 0.514286
206 0.514286
298 0.514286
294 0.514286
290 0.514286
from matplotlib import patches
from numpy import NaN
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
!pip install ruptures
import ruptures as rpt
# Charger les données
data = pd.read csv('./Data parametrage/data mnb mathieu 1.csv')
data.fillna('vide', inplace=True)
# Sélectionner les colonnes à analyser
y colonne = 'accuracy'
# Choix du modèle pour trouver les points de ruptures
signal = data[y colonne].values
model = "12"
algo = rpt.Window(width=60, model=model, jump=1).fit(signal)
result = algo.predict(n bkps=2)
```

```
fig, ax = plt.subplots(figsize=(10, 5))
# Choix des paramètre a garder pour l'analyse de répartition
params =
["cleaner getlemmatisation", "cleaner removedigit", 'tfidf lowercase'
,'tfidf stop words']
# params = ['mnb force alpha','mnb fit prior','mnb alpha']
# Creation d'un dataFrame pour enregistrer les paramètre de chaque
modèle
[] = []
for param in params:
  p = data[param].value counts(normalize=True)
  for i in range(len(p)):
    x = p.index.tolist()[i]
    l.append(str(param)+"="+str(x))
mydf = pd.DataFrame(columns=l,index=[0, 1, 2])
# Ajouter tout les point qui corresponde a l'accuracy
ax.plot(data.index, data[y colonne], 'x', color='black')
my row=[]
for i, (start, end) in enumerate(zip([0] + result, result +
[len(signal)])):
    segment = data.iloc[start:end]
    # Calcul de la proportion de chaque parametre dans chaque sous
groupe
    param props = []
    for param in params:
        param value counts =
segment[param].value counts(normalize=True)
        param value props = [f"{count*100:.2f}%" for count in
param value counts]
        param value legend = " / ".join([f"{param}={param value}]
({param_value_props[j]})  for j, param_value in
enumerate(param value counts.index)])
        param props.append(param value legend)
        # Pour creer mon dataframe avec les paramètres
        for j, param value in enumerate(param value counts.index):
          k=str(param)+"="+str(param value)
          param_value_counts_df = param_value_counts.reset_index()
          param value counts df =
param_value_counts_df.rename(columns={param: 'Parametre', 0:
'Pourcentage'})
          mydf.loc[i][k]=param value counts df.loc[j, 'Parametre']
    # joindre la legende
    segment_legend = " / ".join(param_props)
```

```
# ajouter la droite de regression
    sns.regplot(x=segment.index, y=y colonne, data=segment, ax=ax,
color=f'C{i+1}',
                label=f'Segment {i+1}', scatter=False)
    # afficher le début et la fin de chaque segment
    if(start != len(data[y colonne])):
        ax.text(start, segment[y colonne].min(), f'start: {start}',
fontsize=8)
        if start not in my row:
            my_row.append(start)
    if(end-1 != len(data[y colonne])):
        ax.text(end, segment[y colonne].max(), f'end: {end-1}',
fontsize=8)
        if end-1 not in my row:
            my row.append(end-1)
# Mise en page de la figure
ax.set xlabel('Index')
ax.set_ylabel(y_colonne)
ax.legend(loc='lower center', ncol=1)
plt.show()
fig.savefig('data svm mathieu 1 tot.png', dpi=300,
bbox inches='tight')
# créer le graphique
fig, ax = plt.subplots(figsize=(8, 6))
mydf.plot(kind='bar', ax=ax)
# ajouter des étiquettes
ax.set xlabel('Segment')
ax.set ylabel('Proportion des paramètres')
legend = ax.legend(loc='center left', bbox to anchor=(1.0, 0.5))
# afficher le graphique
plt.show()
Looking in indexes: https://pypi.org/simple, https://us-
python.pkg.dev/colab-wheels/public/simple/
Requirement already satisfied: ruptures in
/usr/local/lib/python3.9/dist-packages (1.1.7)
Requirement already satisfied: numpy in /usr/local/lib/python3.9/dist-
packages (from ruptures) (1.24.3)
Requirement already satisfied: scipy in /usr/local/lib/python3.9/dist-
packages (from ruptures) (1.10.1)
WARNING:matplotlib.text:posx and posy should be finite values
WARNING: matplotlib.text:posx and posy should be finite values
```



WARNING:matplotlib.text:posx and posy should be finite values WARNING:matplotlib.text:posx and posy should be finite values

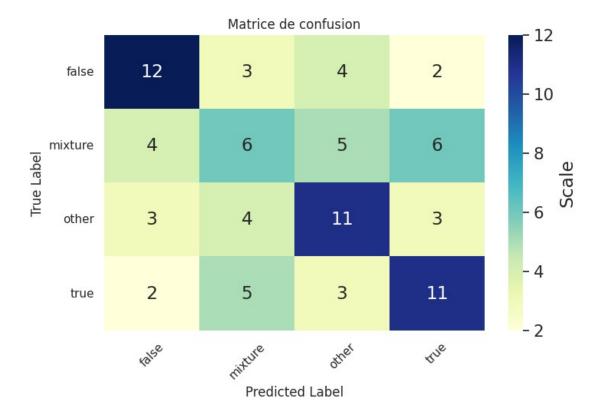


On observe que le segment regroupe qui permet de supprimer les stop word ainsi qu'une majorité de getlemmatisation=False, à l'opposé le segment 1 contient que des prétraitements qui ne supprime pas les stop words et un lowercase=false.

Enregistrement du modele MNB avec les meilleurs paramètres

```
import pickle
from sklearn.naive_bayes import MultinomialNB
from sklearn.model_selection import train_test_split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9
testsize= 0.1
```

```
seed=30
train title, test title, train note, test note=train test split(X train, y
train size=trainsize,random state=seed,test size=testsize,stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=False, stop words='english')),
    ('mnb', MultinomialNB(alpha=0.5, fit prior=True,
force alpha=True))
])
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Mnb final 1.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Mnb final 1.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer(removedigit=True)),
                ('tfidf',
                 TfidfVectorizer(lowercase=False,
stop words='english')),
                ('mnb', MultinomialNB(alpha=0.5, force alpha=True))])
Accuracy: 0.476
Classification Report
              precision
                           recall f1-score
                                               support
                          0.57143
       false
                0.57143
                                    0.57143
                                                    21
                                                    21
                0.33333
                          0.28571
                                    0.30769
     mixture
       other
                0.47826
                          0.52381
                                    0.50000
                                                    21
                0.50000
                          0.52381
                                    0.51163
                                                    21
        true
                                                    84
                                    0.47619
    accuracy
                0.47076
                          0.47619
                                    0.47269
                                                    84
   macro avq
weighted avg
                0.47076
                          0.47619
                                    0.47269
                                                    84
```



### Récapitulatif

MNB: 0.476
 SVM: 0.464
 LR: 0.44
 RFC: 0.476

## Sprint 3 : Classification avec nouvelles données basé sur les titres

other 210

Name: our rating, dtype: int64

testAllModel(X\_train,y\_train,3)

[nltk\_data] Downloading package omw-1.4 to /root/nltk\_data...

Evaluation de MultinomialNB

MultinomialNB: 0.469 (0.042) in 0.244 s

Evaluation de LR

LR: 0.480 (0.057) in 8.327 s

Evaluation de KNN

KNN: 0.407 (0.048) in 0.558 s

Evaluation de CART

CART: 0.425 (0.026) in 4.142 s

Evaluation de RF

RF: 0.451 (0.051) in 12.061 s

Evaluation de SVM

SVM: 0.455 (0.059) in 19.207 s

Le meilleur resultat :

Classifier: LR accuracy: 0.480 (0.057) en 8.327 s

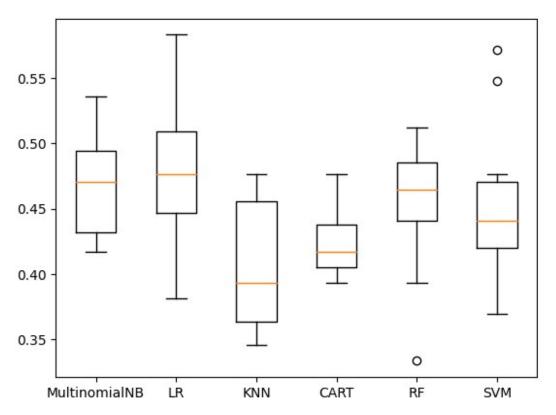
Tous les résultats :

Classifier: LR accuracy: 0.480 (0.057) en 8.327 s

Classifier: MultinomialNB accuracy: 0.469 (0.042) en 0.244 s

Classifier: SVM accuracy: 0.455 (0.059) en 19.207 s Classifier: RF accuracy: 0.451 (0.051) en 12.061 s Classifier: CART accuracy: 0.425 (0.026) en 4.142 s Classifier: KNN accuracy: 0.407 (0.048) en 0.558 s

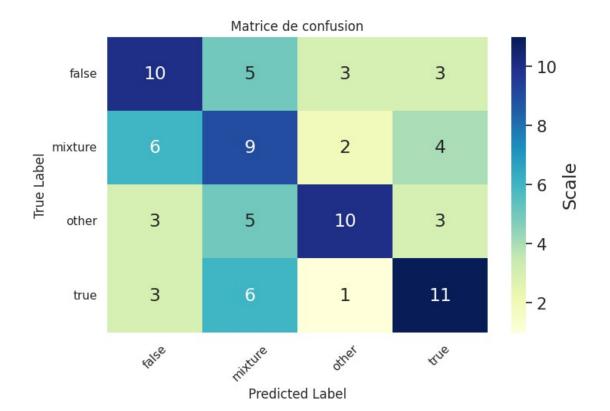
### Comparaison des algorithmes



```
testSVC(X_train, y_train,3,'./Data_parametrage/data_svm_mathieu_2')
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'svm']
parameters:
{'cleaner removedigit': [True, False], 'cleaner getlemmatisation':
[True, False], 'tfidf__stop_words': ['english', None], 'tfidf__lowercase': [True, False], 'svm__C': [0.001, 0.01, 0.1, 1,
      svm_gamma': [0.001, 0.01, 0.1, 1], 'svm kernel': ['linear',
'rbf', 'poly', 'sigmoid']}
Fitting 3 folds for each of 1280 candidates, totalling 3840 fits
[nltk data] Downloading package omw-1.4 to /root/nltk data...
[nltk data]
               Package omw-1.4 is already up-to-date!
réalisé en 72.337 s
Meilleur résultat : 0.445
Ensemble des meilleurs paramètres :
      cleaner__getlemmatisation: False
      cleaner__removedigit: False
      svm_C: \overline{1}
      svm gamma: 0.001
      svm kernel: 'linear'
      tfidf lowercase: True
```

```
tfidf stop words: 'english'
Les premiers résultats :
       cleaner getlemmatisation cleaner removedigit svm C
svm__gamma \
1260
                          False
                                                False
                                                         10.0
0.100
1168
                          False
                                                False
                                                          1.0
0.010
1184
                          False
                                                False
                                                          1.0
0.100
1152
                          False
                                                False
                                                          1.0
0.001
                          False
                                                False
1200
                                                          1.0
1.000
     svm kernel tfidf lowercase tfidf stop words accuracy
1260
         sigmoid
                              True
                                             english 0.445238
                                             english 0.445238
1168
         linear
                              True
1184
          linear
                              True
                                             english 0.445238
          linear
                              True
                                             english 0.445238
1152
1200
          linear
                              True
                                             english 0.445238
from sklearn.model selection import train test split
import pickle
# Création d'un jeu d'apprentissage et de test
trainsize=0.9
testsize= 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
train size=trainsize, random state=seed, test size=testsize, stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=False,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words='english')),
    ('svm', SVC(C=10, gamma=0.1, kernel='sigmoid'))
])
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Svm final 2.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
```

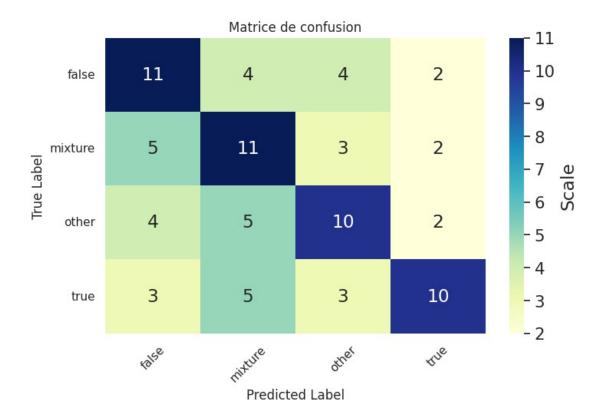
```
# affichage du modèle sauvegardé
print (clf loaded)
# test
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Svm final 2.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer()),
                ('tfidf', TfidfVectorizer(stop words='english')),
                ('svm', SVC(C=10, gamma=0.1, kernel='sigmoid'))])
Accuracy: 0.476
Classification Report
              precision
                           recall f1-score
                                              support
       false
                0.45455
                          0.47619
                                    0.46512
                                                   21
     mixture
                0.36000
                          0.42857
                                    0.39130
                                                   21
                0.62500
                          0.47619
                                    0.54054
                                                   21
       other
        true
                0.52381
                          0.52381
                                    0.52381
                                                   21
                                    0.47619
                                                   84
    accuracy
   macro avq
                0.49084
                          0.47619
                                    0.48019
                                                   84
weighted avg
              0.49084
                          0.47619
                                    0.48019
                                                   84
```



```
testRFC(X train, y train, 3, './Data parametrage/data rfc mathieu 2')
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'rfc']
parameters :
{'cleaner removedigit': [True, False], 'cleaner getlemmatisation':
[True, False], 'tfidf__stop_words': ['english', None],
'tfidf_lowercase': [True, False], 'rfc_n_estimators': [500, 1200],
'rfc__max_depth': [25, 30], 'rfc__min_samples_split': [5, 10, 15],
'rfc__min_samples_leaf': [1, 2]}
Fitting 3 folds for each of 384 candidates, totalling 1152 fits
réalisé en 159.950 s
Meilleur résultat : 0.438
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
     cleaner removedigit: False
     rfc__max_depth: 30
     rfc min samples leaf: 2
     rfc__min_samples_split: 15
     rfc n estimators: 1200
     tfidf lowercase: True
     tfidf stop words: 'english'
Les premiers résultats :
      cleaner getlemmatisation cleaner removedigit rfc max depth
\
```

```
380
                         False
                                                False
                                                                    30
216
                                                                    25
                         False
                                                 True
197
                         False
                                                 True
                                                                    25
72
                          True
                                                 True
                                                                    30
268
                         False
                                                 True
                                                                    30
     rfc__min_samples_leaf rfc__min_samples_split rfc__n_estimators
380
                         2
                                                                   1200
                                                 15
                         2
                                                  5
216
                                                                    500
                         1
                                                  5
197
                                                                   1200
72
                         2
                                                  5
                                                                    500
                         2
268
                                                  5
                                                                   1200
     tfidf lowercase tfidf stop words accuracy
380
                 True
                                 english
                                          0.438095
                 True
                                 english
                                          0.434524
216
197
                 True
                                    None
                                          0.433333
72
                 True
                                 english
                                          0.430952
268
                                          0.429762
                 True
                                 english
import pickle
from sklearn.ensemble import RandomForestClassifier
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9
testsize = 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
train size=trainsize, random state=seed, test size=testsize, stratify=y t
rain)
## double classification a regarder
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=False,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words='english')),
    ('rfc', RandomForestClassifier(max depth=30,min samples leaf=2,
```

```
min samples split=5, n estimators=1200))
1)
pipeline.fit(train_title,train_note)
filename='./Modele/TruevsFalsevsMixturevsOther/Rfc final 2.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Rfc_final_2.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer()),
                ('tfidf', TfidfVectorizer(stop words='english')),
                ('rfc',
                 RandomForestClassifier(max depth=30,
min samples leaf=2,
                                        min samples split=5,
                                        n estimators=1200))])
Accuracy: 0.500
Classification Report
              precision
                          recall f1-score
                                              support
                                    0.50000
       false
                0.47826
                          0.52381
                                                    21
     mixture
                0.44000
                          0.52381
                                    0.47826
                                                    21
                0.50000
                          0.47619
                                    0.48780
                                                   21
       other
        true
                0.62500
                          0.47619
                                    0.54054
                                                   21
                                    0.50000
                                                   84
    accuracy
                0.51082
                          0.50000
                                    0.50165
                                                   84
   macro avg
                                                    84
weighted avg
                0.51082
                          0.50000
                                    0.50165
```



testLR(X train, y train, 3, './Data parametrage/data lr mathieu 2') Application de gridsearch ... pipeline : ['cleaner', 'tfidf', 'lr'] parameters : {'cleaner removedigit': [True, False], 'cleaner getlemmatisation': [True, False], 'tfidf\_\_stop\_words': ['english', None], 'tfidf\_lowercase': [True, False], 'lr\_solver': ['newton-cg', 'lbfgs', 'liblinear'], 'lr\_\_penalty': ['l2'], 'lr\_\_C': [100, 10, 1.0, 0.1, 0.01]} Fitting 3 folds for each of 240 candidates, totalling 720 fits réalisé en 11.016 s Meilleur résultat : 0.448 Ensemble des meilleurs paramètres : cleaner\_\_getlemmatisation: False cleaner removedigit: False  $lr_C: \overline{0.1}$ lr\_\_penalty: 'l2' lr solver: 'newton-cg' tfidf\_lowercase: True tfidf stop words: 'english' Les premiers résultats : cleaner getlemmatisation cleaner removedigit lr C lr penalty \

False

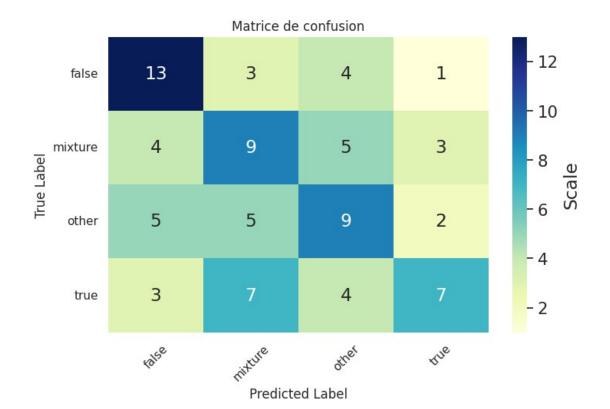
0.1

False

216

```
12
220
                         False
                                                False
                                                         0.1
12
212
                         False
                                                False
                                                         1.0
12
25
                          True
                                                True
                                                         1.0
12
29
                          True
                                                 True
                                                         1.0
12
    lr solver tfidf lowercase tfidf stop words accuracy
216 newton-cq
                            True
                                           english 0.447619
220
         lbfas
                            True
                                           english 0.447619
212 liblinear
                            True
                                           english 0.445238
25
     newton-cq
                            True
                                              None 0.445238
29
                            True
                                              None 0.445238
         lbfqs
import pickle
from sklearn.linear model import LogisticRegression
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9
testsize= 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
train size=trainsize,random state=seed,test size=testsize,stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=False.
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words='english')),
    ('lr', LogisticRegression(C=0.1,penalty='l2', solver='newton-cg'))
1)
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Lr final 2.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf_loaded)
```

```
y_pred = clf_loaded.predict(test_title)
# autres mesures et matrice de confusion
MyshowAllScores(test_note,y_pred)
Sauvegarde du modèle dans ./Modele/final/Lr_final_2.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer()),
                ('tfidf', TfidfVectorizer(stop_words='english')),
                ('lr', LogisticRegression(C=0.1, solver='newton-
cg'))])
Accuracy: 0.452
Classification Report
              precision
                           recall f1-score
                                               support
                0.52000
       false
                          0.61905
                                    0.56522
                                                    21
                          0.42857
     mixture
                0.37500
                                    0.40000
                                                    21
                          0.42857
                                                    21
       other
                0.40909
                                    0.41860
                0.53846
                          0.33333
                                    0.41176
                                                    21
        true
                                    0.45238
                                                    84
    accuracy
                0.46064
                          0.45238
                                    0.44890
                                                    84
   macro avg
                0.46064
                                    0.44890
                                                    84
weighted avg
                          0.45238
```

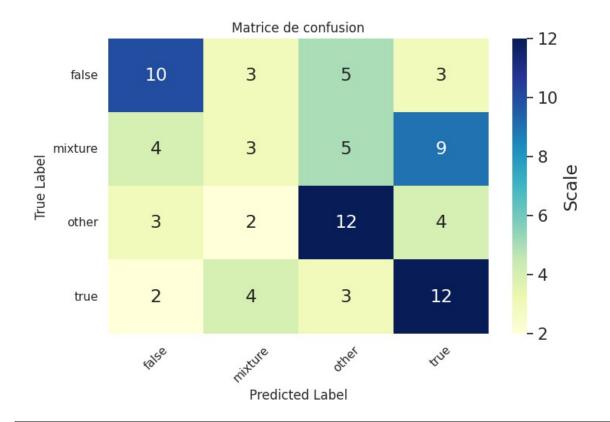


testMNB(X\_train, y\_train,3,'./Data\_parametrage/data\_mnb\_mathieu\_2')

```
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'mnb']
parameters :
{'cleaner removedigit': [True, False], 'cleaner getlemmatisation':
[True, False], 'tfidf stop words': ['english', None],
'tfidf__lowercase': [True, False], 'mnb__alpha': array([0.5, 0.7, 0.9,
1.1, 1.\overline{3}, 1.5), 'mnb fit prior': [True, False], 'mnb force alpha':
[True, False]}
Fitting 3 folds for each of 384 candidates, totalling 1152 fits
réalisé en 14.032 s
Meilleur résultat : 0.449
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
     cleaner__removedigit: False
     mnb_alpha: 1.1
     mnb fit prior: True
     mnb force alpha: True
     tfidf_lowercase: True
     tfidf stop words: None
Les premiers résultats :
      cleaner__getlemmatisation cleaner__removedigit mnb__alpha \
345
                         False
                                               False
                                                             1.1
                                                             1.1
341
                         False
                                               False
349
                         False
                                               False
                                                             1.1
337
                         False
                                               False
                                                             1.1
253
                         False
                                                True
                                                             1.1
     mnb fit prior mnb force alpha tfidf lowercase
tfidf stop words \
345
              False
                                 True
                                                   True
None
341
               True
                                False
                                                   True
None
                                False
349
              False
                                                   True
None
337
               True
                                 True
                                                   True
None
253
              False
                                False
                                                   True
None
     accuracy
345
    0.448810
341 0.448810
349 0.448810
337 0.448810
253 0.446429
import pickle
from sklearn.naive bayes import MultinomialNB
```

```
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9
testsize= 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
train size=trainsize, random state=seed, test size=testsize, stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=False,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words=None)),
    ('mnb', MultinomialNB(alpha=1.1, fit_prior=False,
force alpha=True))
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Mnb final 2.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Mnb final 2.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer()), ('tfidf',
TfidfVectorizer()),
                ('mnb',
                 MultinomialNB(alpha=1.1, fit prior=False,
force alpha=True))])
Accuracy: 0.440
Classification Report
                         recall f1-score
              precision
                                              support
       false
                0.52632
                          0.47619
                                    0.50000
                                                   21
                0.25000
                          0.14286
                                                    21
     mixture
                                    0.18182
```

other true	0.48000 0.42857	0.57143 0.57143	0.52174 0.48980	21 21
accuracy			0.44048	84
macro avg	0.42122	0.44048	0.42334	84
weighted avg	0.42122	0.44048	0.42334	84



**Sprint 4 : Double classification avec nouvelles données** 

- Etape 1 : Premiere classification sur True/False vs Other/mixture
- Etape 2 : Seconde classification sur Other vs mixture avec les données venant de Other/mixture
- Etape 3 : Seconde classification sur True vs FAlse avec les données venant de True/False
- Etape 4 : Mise en forme de la fonction

```
Etape 1: Premiere classification sur True vs False vs Other/mixture
mySample = pd.read csv('./Data equilibre/MyData Sprintlet2.csv',
sep=",")
mySample['notation'] = mySample['our rating']
for i in range(0,len(mySample['notation'])):
     if mySample['notation'][i] == 'false' or mySample['notation'][i]
== 'true':
         mySample['notation'][i] = 'false/true'
     if mySample['notation'][i] == 'other' or mySample['notation'][i]
== 'mixture':
         mySample['notation'][i] = 'other/mixture'
print(mySample['notation'].value counts())
X train = mySample['text']
y train = mySample['notation']
z train = mySample['our rating']
false/true
                 420
                 420
other/mixture
Name: notation, dtype: int64
<ipython-input-13-edb7777ad9d1>:7: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame
See the caveats in the documentation:
https://pandas.pydata.org/pandas-docs/stable/user guide/indexing.html#
returning-a-view-versus-a-copy
  mySample['notation'][i] = 'false/true'
<ipython-input-13-edb7777ad9d1>:9: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame
See the caveats in the documentation:
https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#
returning-a-view-versus-a-copy
 mySample['notation'][i] = 'other/mixture'
testAllModel(X train,y train,3)
[nltk data] Downloading package omw-1.4 to /root/nltk data...
[nltk data] Package omw-1.4 is already up-to-date!
Evaluation de MultinomialNB
MultinomialNB : 0.648 (0.044) in 1.360 s
Evaluation de LR
LR: 0.651 (0.049) in 9.330 s
```

Evaluation de KNN

KNN: 0.586 (0.057) in 2.710 s

Evaluation de CART

CART : 0.560 (0.062) in 27.253 s

Evaluation de RF

RF: 0.637 (0.043) in 24.054 s

Evaluation de SVM

SVM : 0.658 (0.051) in 181.455 s

Le meilleur resultat :

Classifier: SVM accuracy: 0.658 (0.051) en 181.455 s

#### Tous les résultats :

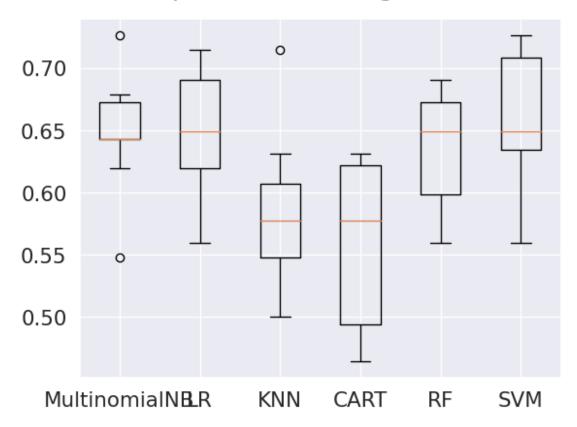
Classifier: SVM accuracy: 0.658 (0.051) en 181.455 s

Classifier: LR accuracy: 0.651 (0.049) en 9.330

Classifier: MultinomialNB accuracy: 0.648 (0.044) en 1.360

Classifier: RF accuracy: 0.637 (0.043) en 24.054 s Classifier: KNN accuracy: 0.586 (0.057) en 2.710 s Classifier: CART accuracy: 0.560 (0.062) en 27.253

# Comparaison des algorithmes

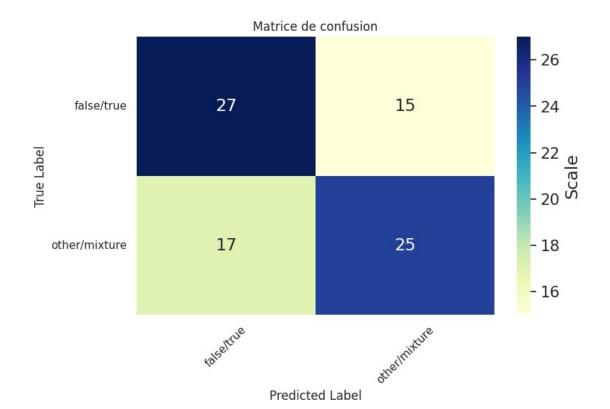


testSVC(X\_train, y\_train,3,"./Data\_parametrage/data\_svm\_mat\_4\_1")

```
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'svm']
parameters:
{'cleaner__removedigit': [True, False], 'cleaner getlemmatisation':
[True, False], 'tfidf stop words': ['english', None],
'tfidf__lowercase': [True, False], 'svm__C': [0.001, 0.01, 0.1, 1,
10], 'svm gamma': [0.001, 0.01, 0.1, 1], 'svm kernel': ['linear',
'rbf', 'poly', 'sigmoid']}
Fitting 3 folds for each of 1280 candidates, totalling 3840 fits
[nltk data] Downloading package omw-1.4 to /root/nltk data...
             Package omw-1.4 is already up-to-date!
réalisé en 984.092 s
Meilleur résultat : 0.569
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
     cleaner__removedigit: True
     svm C: 10
     svm__gamma: 1
     svm kernel: 'sigmoid'
     tfidf lowercase: True
     tfidf stop words: 'english'
Les premiers résultats :
       cleaner__getlemmatisation cleaner__removedigit svm__C
svm gamma \
956
                          False
                                                True
                                                         10.0
1.00
1276
                         False
                                                False
                                                         10.0
1.00
                          False
                                                False
                                                         10.0
1248
0.10
                          False
                                                False
                                                         10.0
1264
1.00
1232
                          False
                                                False
                                                         10.0
0.01
    svm kernel tfidf lowercase tfidf stop words accuracy
956
         sigmoid
                              True
                                            english 0.569048
                             True
1276
         sigmoid
                                            english 0.565476
1248
         linear
                             True
                                            english 0.564286
1264
         linear
                             True
                                             english 0.564286
1232
         linear
                             True
                                             english 0.564286
from sklearn.model selection import train test split
import pickle
# Création d'un jeu d'apprentissage et de test
trainsize=0.9 # 70% pour le jeu d'apprentissage, il reste 30% du jeu
de données pour
testsize= 0.1
```

```
seed=30
```

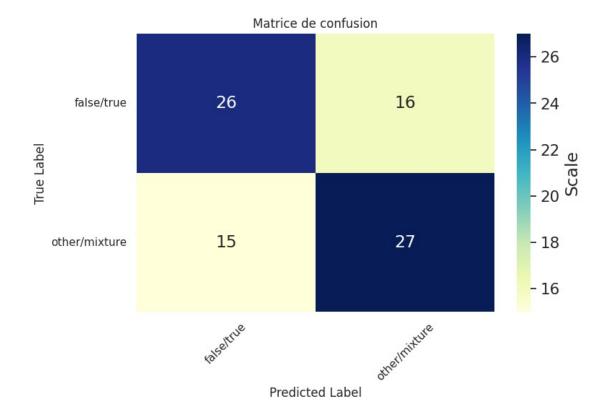
```
train title, test title, train note, test note, train rating, test rating=t
rain test split(X train, y train, z train,
train size=trainsize,random state=seed,test size=testsize,stratify=z t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words='english')),
    ('svm', SVC(C=10, gamma=1, kernel='sigmoid'))
1)
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Svm final 4.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test avec les données qu'il a apprise c'est parfait woahhha c'est
beau
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Svm final 4.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer(removedigit=True)),
                ('tfidf', TfidfVectorizer(stop words='english')),
                ('svm', SVC(C=10, gamma=1, kernel='sigmoid'))])
Accuracy: 0.619
Classification Report
               precision
                            recall f1-score
                                               support
                 0.61364
                           0.64286
                                     0.62791
                                                     42
   false/true
other/mixture
                           0.59524
                                                     42
                 0.62500
                                     0.60976
     accuracy
                                     0.61905
                                                     84
                 0.61932
                           0.61905
                                     0.61883
                                                     84
    macro avq
                 0.61932
                           0.61905
                                     0.61883
                                                     84
 weighted avg
```



```
testRFC(X_train, y_train,3,"./Data_parametrage/data_rfc_mat_4_1")
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'rfc']
parameters :
{'cleaner removedigit': [True, False], 'cleaner getlemmatisation':
[True, False], 'tfidf stop words': ['english', None],
'tfidf__lowercase': [True, False], 'rfc__n_estimators': [500, 1200],
'rfc__max_depth': [25, 30], 'rfc__min_samples_split': [5, 10, 15],
'rfc__min_samples_leaf': [1, 2]}
Fitting 3 folds for each of 384 candidates, totalling 1152 fits
réalisé en 466.706 s
Meilleur résultat : 0.551
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
     cleaner removedigit: False
     rfc_{max_depth}: 30
     rfc min samples leaf: 2
     rfc__min_samples_split: 10
     rfc n estimators: 500
     tfidf lowercase: True
     tfidf stop words: 'english'
Les premiers résultats :
      cleaner getlemmatisation cleaner removedigit rfc max depth
/
```

```
368
                         False
                                                False
                                                                   30
280
                         False
                                                 True
                                                                   30
80
                          True
                                                 True
                                                                   30
240
                         False
                                                 True
                                                                   30
236
                         False
                                                 True
                                                                   25
     rfc min samples leaf rfc min samples split rfc n estimators
368
                         2
                                                 10
                                                                   500
280
                         2
                                                 15
                                                                   500
                         2
80
                                                 10
                                                                   500
                         1
                                                  5
240
                                                                   500
                         2
236
                                                 15
                                                                   1200
     tfidf lowercase tfidf stop words accuracy
368
                 True
                                english
                                          0.551190
280
                 True
                                english 0.547619
80
                 True
                                english
                                         0.546429
240
                 True
                                english 0.546429
236
                                english 0.545238
                 True
import pickle
from sklearn.ensemble import RandomForestClassifier
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9 # 70% pour le jeu d'apprentissage, il reste 30% du jeu
de données pour
testsize= 0.1
seed=30
train title, test title, train note, test note, train rating, test rating=t
rain_test_split(X_train,y_train,z_train,
train size=trainsize, random state=seed, test size=testsize, stratify=z t
rain)
## double classification a regarder
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=False,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words='english')),
```

```
('rfc', RandomForestClassifier(max depth=30,min samples leaf=2,
min samples split=10, n estimators=500))
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Rfc final 4.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test avec les données qu'il a apprise c'est parfait woahhha c'est
beau
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Rfc final 4.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer()),
                ('tfidf', TfidfVectorizer(stop_words='english')),
                ('rfc',
                 RandomForestClassifier(max depth=30,
min samples leaf=2,
                                        min samples split=10,
                                        n estimators=500))])
Accuracy: 0.631
Classification Report
               precision
                          recall f1-score
                                               support
   false/true
                 0.63415
                           0.61905
                                     0.62651
                                                    42
other/mixture
                 0.62791
                           0.64286
                                     0.63529
                                                    42
                                                    84
                                     0.63095
     accuracy
                 0.63103
                           0.63095
                                     0.63090
                                                    84
    macro avg
                           0.63095
                                                    84
 weighted avg
                 0.63103
                                     0.63090
```



testLR(X\_train, y\_train,3,'./Data\_parametrage/data\_lr\_mat\_4')

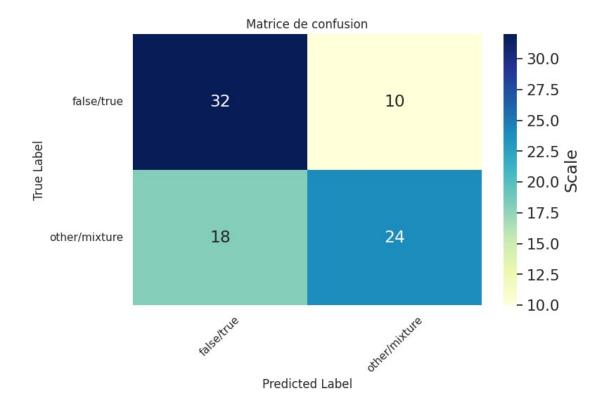
```
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'lr']
parameters :
{'cleaner__removedigit': [True, False], 'cleaner__getlemmatisation':
[True, False], 'tfidf__stop_words': ['english', None],
'tfidf__lowercase': [True, False], 'lr__solver': ['newton-cg',
'lbfgs', 'liblinear'], 'lr__penalty': ['l2'], 'lr__C': [100, 10, 1.0,
0.1, 0.01]}
Fitting 3 folds for each of 240 candidates, totalling 720 fits
/usr/local/lib/python3.9/dist-packages/joblib/externals/loky/
process_executor.py:700: UserWarning:
```

A worker stopped while some jobs were given to the executor. This can be caused by a too short worker timeout or by a memory leak.

```
réalisé en 181.829 s
Meilleur résultat : 0.560
Ensemble des meilleurs paramètres :
    cleaner__getlemmatisation: False
    cleaner__removedigit: True
    lr__C: 100
    lr__penalty: 'l2'
    lr solver: 'newton-cg'
```

```
tfidf lowercase: True
     tfidf stop words: None
Les premiers résultats :
      cleaner_getlemmatisation cleaner removedigit lr C
lr penalty \
121
                         False
                                                True
                                                      100.0
12
125
                         False
                                                True
                                                      100.0
12
129
                         False
                                                      100.0
                                                True
12
120
                         False
                                                True
                                                      100.0
12
128
                         False
                                                True 100.0
12
    lr solver tfidf lowercase tfidf stop words accuracy
121 newton-cq
                            True
                                              None 0.559524
125
        lbfgs
                            True
                                              None 0.559524
129 liblinear
                            True
                                              None 0.558333
120 newton-cq
                            True
                                           english 0.557143
128 liblinear
                            True
                                           english 0.557143
from os import truncate
import pickle
from sklearn.linear model import LogisticRegression
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9 # 70% pour le jeu d'apprentissage, il reste 30% du jeu
de données pour
testsize = 0.1
seed=30
train title, test title, train note, test note, train rating, test rating=t
rain test split(X train,y train,z train,
train size=trainsize,random state=seed,test size=testsize,stratify=z t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words=None)),
    ('lr', LogisticRegression(C=100,penalty='l2', solver='newton-cg'))
1)
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Lr final 4.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
```

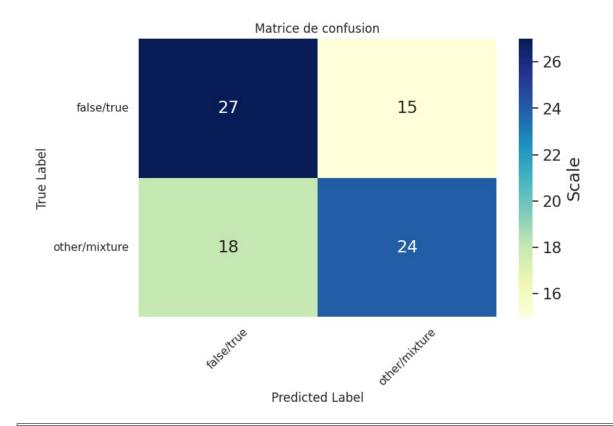
```
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test avec les données qu'il a apprise c'est parfait woahhha c'est
beau
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test_note,y_pred)
Sauvegarde du modèle dans ./Modele/final/Lr final 4.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer(removedigit=True)),
                ('tfidf', TfidfVectorizer()),
                ('lr', LogisticRegression(C=100, solver='newton-
cq'))])
Accuracy: 0.667
Classification Report
               precision
                            recall f1-score
                                               support
   false/true
                 0.64000
                           0.76190
                                     0.69565
                                                    42
                 0.70588
                           0.57143
                                     0.63158
                                                    42
other/mixture
                                     0.66667
                                                    84
     accuracy
                           0.66667
                                     0.66362
                                                    84
    macro avg
                 0.67294
weighted avg
                 0.67294
                           0.66667
                                     0.66362
                                                    84
```



```
testMNB(X train, y train, 3, "./Data parametrage/data mnb mat 4 1")
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'mnb']
parameters:
{'cleaner__removedigit': [True, False], 'cleaner__getlemmatisation':
[True, False], 'tfidf_stop_words': ['english', None], 'tfidf_lowercase': [True, False], 'mnb_alpha': array([0.5, 0.7, 0.9,
1.1, 1.\overline{3}, 1.5), 'mnb fit prior': [True, False], 'mnb force alpha':
[True, False]}
Fitting 3 folds for each of 384 candidates, totalling 1152 fits
réalisé en 250.272 s
Meilleur résultat : 0.529
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
      cleaner__removedigit: True
     mnb alpha: 0.5
     mnb__fit_prior: True
     mnb force alpha: True
     tfidf lowercase: True
     tfidf stop words: None
Les premiers résultats :
      cleaner getlemmatisation cleaner removedigit mnb alpha \
197
                          False
                                                   True
                                                                  0.5
193
                           False
                                                   True
                                                                  0.5
                           False
                                                                  0.5
205
                                                   True
```

```
201
                         False
                                                 True
                                                              0.5
297
                         False
                                                False
                                                              0.5
     mnb fit prior mnb force alpha tfidf lowercase
tfidf stop words \
197
               True
                                False
                                                    True
None
193
               True
                                 True
                                                    True
None
205
              False
                                False
                                                    True
None
201
              False
                                 True
                                                    True
None
              False
297
                                 True
                                                    True
None
     accuracy
197
    0.528571
193 0.528571
205 0.528571
201 0.528571
297 0.526190
import pickle
from sklearn.naive bayes import MultinomialNB
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9 # 70% pour le jeu d'apprentissage, il reste 30% du jeu
de données pour
testsize= 0.1
seed=30
train title, test title, train note, test note, train rating, test rating=t
rain test split(X train, y train, z train,
train size=trainsize, random state=seed, test size=testsize, stratify=z t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words=None)),
    ('mnb', MultinomialNB(alpha=0.5, fit prior=True,
force alpha=False))
1)
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Mnb final 4.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
```

```
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test avec les données qu'il a apprise c'est parfait woahhha c'est
beau
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test_note,y_pred)
Sauvegarde du modèle dans ./Modele/final/Mnb_final_4.pkl
Chargement du modèle
('mnb', MultinomialNB(alpha=0.5, force alpha=False))])
Accuracy: 0.607
Classification Report
              precision
                         recall f1-score
                                           support
  false/true
               0.60000
                         0.64286
                                  0.62069
                                                42
other/mixture
               0.61538
                         0.57143
                                  0.59259
                                                42
                                  0.60714
                                                84
    accuracy
   macro avq
               0.60769
                         0.60714
                                  0.60664
                                                84
                                                84
weighted avg
               0.60769
                         0.60714
                                  0.60664
```



Etape 2 : Recherche du meilleure modèle pour la seconde classification sur Other vs mixture avec les données classé pour Other/mixture

```
mySample2 = mySample.loc[~mySample['our
rating'] isin(["false","true"])]
print(mySample2['our rating'].value counts())
X train = mySample2['text']
y train = mySample2['our rating']
mixture
           210
other
           210
Name: our rating, dtype: int64
testAllModel(X_train,y_train,3)
[nltk_data] Downloading package omw-1.4 to /root/nltk_data...
[nltk data]
              Package omw-1.4 is already up-to-date!
Evaluation de MultinomialNB
MultinomialNB : 0.710 (0.064) in 0.609 s
Evaluation de LR
LR: 0.740 (0.062) in 4.222 s
Evaluation de KNN
```

KNN: 0.676 (0.068) in 1.629 s

Evaluation de CART

CART: 0.640 (0.076) in 5.260 s

Evaluation de RF

RF: 0.731 (0.059) in 7.568 s

Evaluation de SVM

SVM: 0.752 (0.065) in 19.815 s

Le meilleur resultat :

Classifier: SVM accuracy: 0.752 (0.065) en 19.815 s

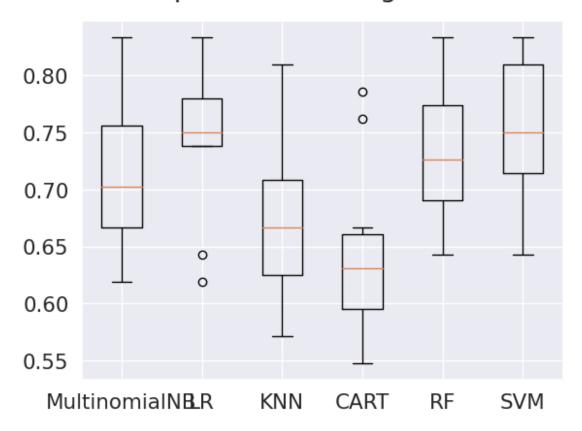
#### Tous les résultats :

Classifier: SVM accuracy: 0.752 (0.065) en 19.815 s Classifier: LR accuracy: 0.740 (0.062) en 4.222 s Classifier: RF accuracy: 0.731 (0.059) en 7.568 s

Classifier: MultinomialNB accuracy: 0.710 (0.064) en 0.609

Classifier: KNN accuracy: 0.676 (0.068) en 1.629 s Classifier: CART accuracy: 0.640 (0.076) en 5.260 s

# Comparaison des algorithmes

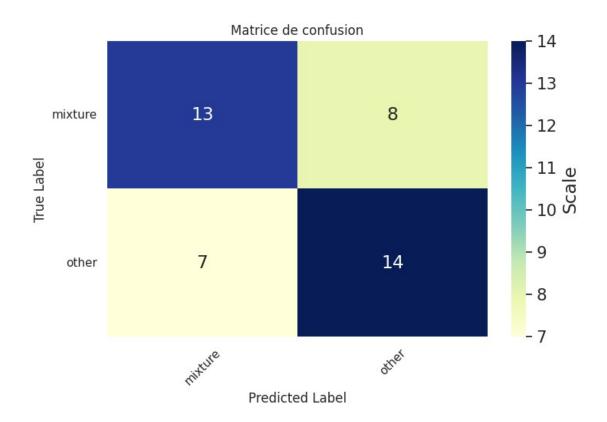


testSVC(X\_train, y\_train,3,"./Data\_parametrage/data\_svm\_mat\_4\_2")

```
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'svm']
parameters :
{'cleaner__removedigit': [True, False], 'cleaner getlemmatisation':
[True, False], 'tfidf stop words': ['english', None],
'tfidf__lowercase': [True, False], 'svm__C': [0.001, 0.01, 0.1, 1,
10], 'svm gamma': [0.001, 0.01, 0.1, 1], 'svm kernel': ['linear',
'rbf', 'poly', 'sigmoid']}
Fitting 3 folds for each of 1280 candidates, totalling 3840 fits
[nltk data] Downloading package omw-1.4 to /root/nltk_data...
              Package omw-1.4 is already up-to-date!
[nltk data]
/usr/local/lib/python3.9/dist-packages/joblib/externals/loky/process e
xecutor.py:700: UserWarning: A worker stopped while some jobs were
given to the executor. This can be caused by a too short worker
timeout or by a memory leak.
 warnings.warn(
réalisé en 426.727 s
Meilleur résultat : 0.717
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: True
     cleaner__removedigit: True
     svm C: 1
     svm__gamma: 0.001
     svm kernel: 'linear'
     tfidf lowercase: False
     tfidf stop words: 'english'
Les premiers résultats :
      cleaner getlemmatisation cleaner removedigit svm C
svm gamma \
210
                          True
                                                True
                                                         1.0
0.010
194
                          True
                                                True
                                                         1.0
0.001
226
                          True
                                                True
                                                         1.0
0.100
302
                          True
                                                True
                                                        10.0
0.100
242
                          True
                                                True
                                                         1.0
1.000
    svm_kernel tfidf_lowercase tfidf_stop_words
                                                     accuracy
210
         linear
                            False
                                            english
                                                     0.716667
194
         linear
                            False
                                            english
                                                     0.716667
226
        linear
                            False
                                            english
                                                     0.716667
302
                                            english
        sigmoid
                            False
                                                     0.716667
242
        linear
                            False
                                            english
                                                     0.716667
```

```
from sklearn.model selection import train test split
import pickle
# Création d'un jeu d'apprentissage et de test
trainsize=0.9 # 70% pour le jeu d'apprentissage, il reste 30% du jeu
de données pour
testsize= 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
train,
train size=trainsize,random state=seed,test size=testsize,stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=True)),
    ("tfidf", TfidfVectorizer(lowercase=False, stop words='english')),
    ('svm', SVC(C=1, gamma=0.01, kernel='linear'))
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Svm final 4 step2.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf_loaded)
# test avec les données qu'il a apprise c'est parfait woahhha c'est
beau
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note, y pred)
Sauvegarde du modèle dans ./Modele/final/Svm final 4 step2.pkl
Chargement du modèle
Pipeline(steps=[('cleaner',
                 TextNormalizer(getlemmatisation=True,
removedigit=True)),
                ('tfidf',
                 TfidfVectorizer(lowercase=False,
stop words='english')),
                ('svm', SVC(C=1, gamma=0.01, kernel='linear'))])
Accuracy: 0.643
Classification Report
```

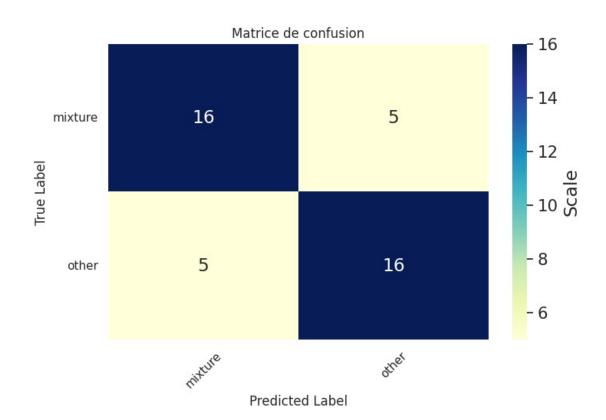
	precision	recall	f1-score	support
mixture other	0.65000 0.63636	0.61905 0.66667	0.63415 0.65116	21 21
accuracy macro avg weighted avg	0.64318 0.64318	0.64286 0.64286	0.64286 0.64265 0.64265	42 42 42



```
rfc max depth: 25
     rfc min samples leaf: 2
     rfc__min_samples_split: 15
     rfc n estimators: 500
     tfidf lowercase: True
     tfidf stop words: None
Les premiers résultats :
     cleaner getlemmatisation cleaner removedigit rfc max depth
\
137
                          True
                                               False
                                                                  25
349
                         False
                                               False
                                                                   30
5
                                                                  25
                          True
                                                True
372
                         False
                                               False
                                                                   30
53
                          True
                                                True
                                                                  30
     rfc__min_samples_leaf rfc__min_samples_split rfc__n_estimators
137
                         2
                                                15
                                                                   500
349
                         1
                                                10
                                                                  1200
5
                                                 5
                         1
                                                                 1200
372
                         2
                                                10
                                                                 1200
53
                         1
                                                 5
                                                                  1200
     tfidf lowercase tfidf stop words
                                         accuracy
137
                 True
                                   None
                                         0.719048
349
                 True
                                   None
                                         0.716667
5
                 True
                                   None
                                         0.714286
372
                 True
                                english
                                         0.711905
53
                 True
                                   None
                                         0.711905
import pickle
from sklearn.ensemble import RandomForestClassifier
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9 # 70% pour le jeu d'apprentissage, il reste 30% du jeu
de données pour
testsize= 0.1
seed=30
```

```
train title, test title, train note, test note=train test split(X train, y
train,
train size=trainsize,random state=seed,test size=testsize,stratify=y t
rain) # stratified = ves
## double classification a regarder
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=False,
getlemmatisation=True)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words=None)),
    ('rfc', RandomForestClassifier(max depth=25,min samples leaf=2,
min samples split=15, n estimators=500))
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Rfc final 4 step2.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf_loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test avec les données qu'il a apprise c'est parfait woahhha c'est
beau
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Rfc final 4 step2.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer(getlemmatisation=True)),
                ('tfidf', TfidfVectorizer()),
                ('rfc',
                 RandomForestClassifier(max depth=25,
min samples leaf=2,
                                        min samples split=15,
                                        n estimators=500))])
Accuracy: 0.762
Classification Report
              precision
                           recall f1-score
                                              support
                0.76190
                          0.76190
                                    0.76190
     mixture
                                                   21
       other
                0.76190
                          0.76190
                                    0.76190
                                                   21
```

```
accuracy 0.76190 42
macro avg 0.76190 0.76190 0.76190 42
weighted avg 0.76190 0.76190 0.76190 42
```

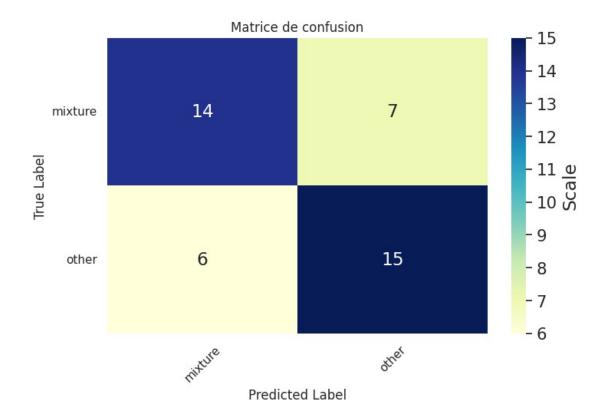


testLR(X\_train, y\_train,3,"./Data\_parametrage/data\_lr\_mat\_4\_2")

```
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'lr']
parameters :
{'cleaner__removedigit': [True, False], 'cleaner__getlemmatisation':
[True, False], 'tfidf__stop_words': ['english', None], 'tfidf__lowercase': [True, False], 'lr__solver': ['newton-cg',
'lbfgs', 'liblinear'], 'lr__penalty': ['l2'], 'lr__C': [100, 10, 1.0,
0.1, 0.01
Fitting 3 folds for each of 240 candidates, totalling 720 fits
réalisé en 71.005 s
Meilleur résultat : 0.721
Ensemble des meilleurs paramètres :
      cleaner__getlemmatisation: False
      cleaner__removedigit: True
      lr C: \overline{10}
      lr__penalty: 'l2'
      lr solver: 'newton-cg'
      tfidf lowercase: False
      tfidf stop words: 'english'
```

```
Les premiers résultats :
      cleaner getlemmatisation cleaner removedigit lr C
lr penalty \
134
                         False
                                                True
                                                       10.0
12
138
                         False
                                                True
                                                       10.0
12
142
                         False
                                                True
                                                       10.0
12
12
                                                       10.0
                          True
                                                True
12
20
                          True
                                                True
                                                       10.0
12
    lr solver tfidf lowercase tfidf stop words accuracy
134 newton-cq
                           False
                                           english 0.721429
138
                           False
         lbfas
                                           english 0.721429
142 liblinear
                           False
                                           english 0.721429
12
                           True
                                           english 0.716667
     newton-cq
20
                                           english 0.716667
     liblinear
                            True
import pickle
from sklearn.linear model import LogisticRegression
from sklearn.model selection import train test split
# Création d'un ieu d'apprentissage et de test
trainsize=0.9 # 70% pour le jeu d'apprentissage, il reste 30% du jeu
de données pour
testsize = 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
train size=trainsize,random state=seed,test size=testsize,stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=False, stop words='english')),
    ('lr', LogisticRegression(C=10,penalty='l2', solver='newton-cg'))
1)
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Lr final 4 step2.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
```

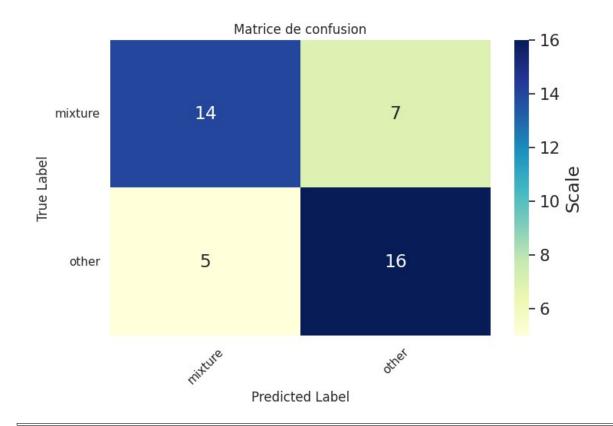
```
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf_loaded)
# test avec les données qu'il a apprise c'est parfait woahhha c'est
beau
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test_note,y_pred)
Sauvegarde du modèle dans ./Modele/final/Lr final 4 step2.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer(removedigit=True)),
                ('tfidf',
                TfidfVectorizer(lowercase=False,
stop words='english')),
                ('lr', LogisticRegression(C=10, solver='newton-cg'))])
Accuracy: 0.690
Classification Report
              precision
                           recall f1-score
                                              support
                0.70000
     mixture
                          0.66667
                                    0.68293
                                                   21
       other
               0.68182
                          0.71429
                                    0.69767
                                                   21
                                                   42
                                    0.69048
    accuracy
             0.69091
                                                   42
   macro avg
                          0.69048
                                    0.69030
                                                   42
weighted avg
             0.69091
                          0.69048
                                    0.69030
```



testMNB(X train, y train, 3, "./Data parametrage/data mnb mat 4 2") Application de gridsearch ... pipeline : ['cleaner', 'tfidf', 'mnb'] parameters : {'cleaner removedigit': [True, False], 'cleaner getlemmatisation': [True, False], 'tfidf\_\_stop\_words': ['english', None], 'tfidf\_\_lowercase': [True, False], 'mnb\_\_alpha': array([0.5, 0.7, 0.9, 1.1, 1.3, 1.5]), 'mnb\_\_fit\_prior': [True, False], 'mnb\_\_force\_alpha': [True, False]} Fitting 3 folds for each of 384 candidates, totalling 1152 fits réalisé en 111.185 s Meilleur résultat : 0.733 Ensemble des meilleurs paramètres : cleaner\_\_getlemmatisation: False cleaner removedigit: True mnb alpha: 0.5 mnb fit prior: True mnb\_\_force\_alpha: True tfidf lowercase: False tfidf stop words: 'english' Les premiers résultats : cleaner getlemmatisation cleaner removedigit mnb alpha \ 194 False True 0.5 False True 0.5 202

```
198
                         False
                                                 True
                                                              0.5
                         False
206
                                                 True
                                                              0.5
238
                         False
                                                 True
                                                              0.9
     mnb fit prior mnb force alpha tfidf lowercase
tfidf stop words \
194
               True
                                 True
                                                   False
english
              False
                                 True
                                                   False
202
enalish
                                False
                                                   False
198
               True
english
206
              False
                                False
                                                   False
english
238
              False
                                False
                                                   False
english
     accuracy
194
    0.733333
202 0.733333
198 0.733333
206 0.733333
238 0.728571
import pickle
from sklearn.naive bayes import MultinomialNB
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9 # 70% pour le jeu d'apprentissage, il reste 30% du jeu
de données pour
testsize= 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
train size=trainsize, random state=seed, test size=testsize, stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=False, stop words='english')),
    ('mnb', MultinomialNB(alpha=0.5, fit prior=True,
force alpha=True))
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Mnb final 4 step2.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
```

```
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test avec les données qu'il a apprise c'est parfait woahhha c'est
beau
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test_note,y_pred)
Sauvegarde du modèle dans ./Modele/final/Mnb final 4 step2.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer(removedigit=True)),
                ('tfidf',
                 TfidfVectorizer(lowercase=False,
stop words='english')),
                ('mnb', MultinomialNB(alpha=0.5, force alpha=True))])
Accuracy: 0.714
Classification Report
              precision
                           recall f1-score
                                              support
                0.73684
                          0.66667
                                    0.70000
                                                   21
     mixture
       other
                0.69565
                          0.76190
                                    0.72727
                                                   21
                                    0.71429
                                                   42
    accuracy
                0.71625
                          0.71429
                                    0.71364
                                                   42
   macro avg
                                                   42
weighted avg
                0.71625
                          0.71429
                                    0.71364
```



Recherche du meilleure modèle pour la seconde classification sur True vs False avec les données classé pour true/false

```
mySample2 = mySample.loc[~mySample['our
rating'].isin(["other","mixture"])]
print(mySample2['our rating'].value_counts())
X train = mySample2['text']
y train = mySample2['our rating']
false
         210
true
         210
Name: our rating, dtype: int64
testAllModel(X_train,y_train,3)
[nltk data] Downloading package omw-1.4 to /root/nltk data...
Evaluation de MultinomialNB
MultinomialNB: 0.721 (0.081) in 0.470 s
Evaluation de LR
LR: 0.738 (0.064) in 3.343 s
Evaluation de KNN
KNN : 0.655 (0.067) in 3.310 s
```

Evaluation de CART

CART: 0.662 (0.061) in 3.646 s

Evaluation de RF

RF: 0.710 (0.077) in 6.557 s

Evaluation de SVM

SVM: 0.757 (0.059) in 19.468 s

Le meilleur resultat :

Classifier: SVM accuracy: 0.757 (0.059)

## Tous les résultats :

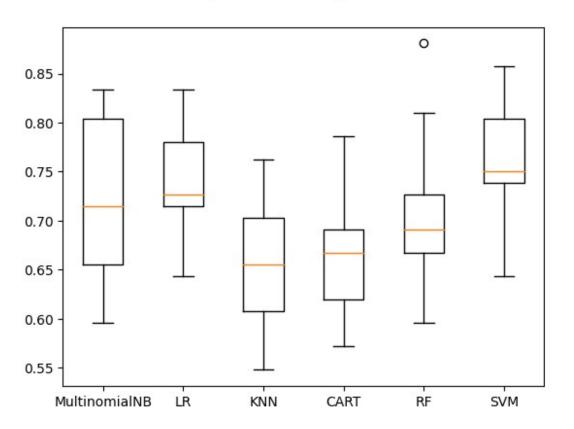
Classifier : SVM accuracy: 0.757 (0.059) en 19.468 S

Classifier: LR accuracy: 0.738 (0.064) en 3.343

Classifier : MultinomialNB accuracy: 0.721 (0.081)en 0.470 S

Classifier: RF accuracy: 0.710 (0.077) en 6.557 Classifier: accuracy: 0.662 (0.061) en 3.646 CART S accuracy: 0.655 (0.067) en 3.310 Classifier : KNN

## Comparaison des algorithmes



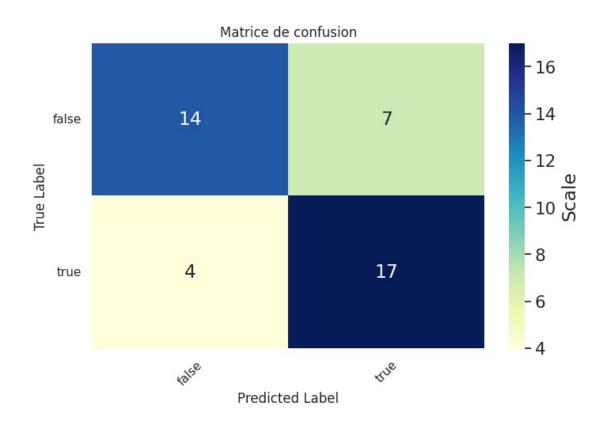
testSVC(X\_train, y\_train,3,"./Data\_parametrage/data\_svm\_mat\_4\_3")

Application de gridsearch ... pipeline : ['cleaner', 'tfidf', 'svm']

```
parameters :
{'cleaner removedigit': [True, False], 'cleaner getlemmatisation':
[True, False], 'tfidf__stop_words': ['english', None], 'tfidf__lowercase': [True, False], 'svm__C': [0.001, 0.01, 0.1, 1,
10], 'svm gamma': [0.001, 0.01, 0.1, 1], 'svm kernel': ['linear',
'rbf', 'poly', 'sigmoid']}
Fitting 3 folds for each of 1280 candidates, totalling 3840 fits
[nltk data] Downloading package omw-1.4 to /root/nltk data...
[nltk data]
              Package omw-1.4 is already up-to-date!
réalisé en 520.696 s
Meilleur résultat : 0.760
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
cleaner__removedigit: False
     svm C: 1
     svm__gamma: 1
     svm kernel: 'sigmoid'
     tfidf__lowercase: False
     tfidf stop words: 'english'
Les premiers résultats :
       cleaner getlemmatisation cleaner removedigit svm C
svm__gamma \
1214
                           False
                                                  False
                                                             1.0
1.00
886
                           False
                                                   True
                                                             1.0
1.00
894
                           False
                                                   True
                                                             1.0
1.00
1170
                           False
                                                  False
                                                             1.0
0.01
1262
                           False
                                                  False
                                                            10.0
0.10
     svm kernel tfidf lowercase tfidf stop words accuracy
                                               english 0.759524
1214
         sigmoid
                              False
886
             rbf
                              False
                                               english 0.757143
894
                              False
                                               english 0.757143
         sigmoid
1170
         linear
                              False
                                               english 0.754762
1262
         sigmoid
                              False
                                               english 0.754762
from sklearn.model selection import train test split
import pickle
# Création d'un jeu d'apprentissage et de test
trainsize=0.9 # 70% pour le jeu d'apprentissage, il reste 30% du jeu
de données pour
testsize= 0.1
seed=30
```

```
train title, test title, train note, test note=train test split(X train, y
train,
train size=trainsize,random state=seed,test size=testsize,stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=False,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=False, stop words='english')),
    ('svm', SVC(C=1, gamma=1, kernel='sigmoid'))
1)
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Svm final 4 step3.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test avec les données qu'il a apprise c'est parfait woahhha c'est
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Svm final 4 step3.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer()),
                ('tfidf',
                 TfidfVectorizer(lowercase=False,
stop words='english')),
                ('svm', SVC(C=1, gamma=1, kernel='sigmoid'))])
Accuracy: 0.738
Classification Report
              precision
                           recall f1-score
                                              support
       false
                0.77778
                          0.66667
                                    0.71795
                                                   21
        true
                0.70833
                          0.80952
                                    0.75556
                                                   21
                                    0.73810
                                                    42
    accuracy
                0.74306
                          0.73810
                                    0.73675
                                                    42
   macro avq
```

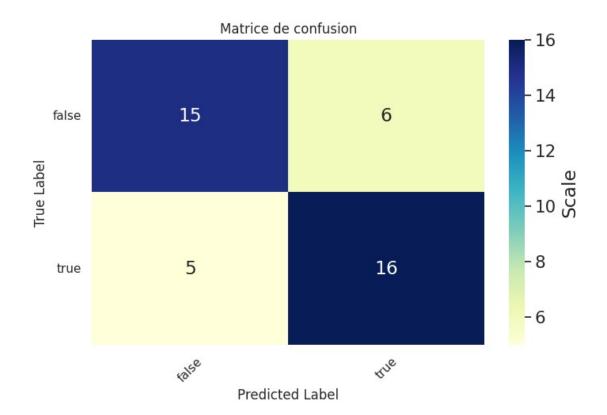
Les premiers résultats :



```
testLR(X train, y train, 3, "./Data parametrage/data lr mat 4 3")
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'lr']
parameters :
{'cleaner removedigit': [True, False], 'cleaner getlemmatisation':
[True, False], 'tfidf__stop_words': ['english', None], 'tfidf__lowercase': [True, False], 'lr__solver': ['newton-cg',
'lbfgs', 'liblinear'], 'lr penalty': ['l2'], 'lr C': [100, 10, 1.0,
0.1, 0.01]}
Fitting 3 folds for each of 240 candidates, totalling 720 fits
réalisé en 88.065 s
Meilleur résultat : 0.762
Ensemble des meilleurs paramètres :
      cleaner__getlemmatisation: False
     cleaner__removedigit: True
     lr__C: 10
     lr_penalty: 'l2'
     lr solver: 'liblinear'
     tfidf lowercase: False
     tfidf stop words: 'english'
```

```
cleaner getlemmatisation cleaner removedigit lr C
lr penalty \overline{\setminus}
142
                                                 True
                         False
                                                        10.0
12
134
                         False
                                                 True
                                                        10.0
12
138
                         False
                                                 True
                                                        10.0
12
22
                          True
                                                 True
                                                        10.0
12
150
                         False
                                                 True
                                                         1.0
12
    lr solver tfidf lowercase tfidf stop words accuracy
142
    liblinear
                           False
                                            english 0.761905
                           False
134
     newton-cq
                                            english 0.759524
138
         lbfqs
                           False
                                            english 0.759524
22
     liblinear
                           False
                                            english 0.759524
150
                           False
         lbfqs
                                            english 0.759524
import pickle
from sklearn.linear model import LogisticRegression
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9 # 70% pour le jeu d'apprentissage, il reste 30% du jeu
de données pour
testsize= 0.1
seed=30
train title, test title, train note, test note=train test split(X train, v
train size=trainsize,random state=seed,test size=testsize,stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=False, stop words='english')),
    ('lr', LogisticRegression(C=10,penalty='l2', solver='liblinear'))
1)
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Lr final 4 step3.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
```

```
print (clf_loaded)
# test avec les données qu'il a apprise c'est parfait woahhha c'est
beau
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Lr final 4 step3.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer(removedigit=True)),
                ('tfidf',
                 TfidfVectorizer(lowercase=False,
stop words='english')),
                ('lr', LogisticRegression(C=10, solver='liblinear'))])
Accuracy: 0.738
Classification Report
              precision
                           recall f1-score
                                              support
       false
               0.75000
                         0.71429
                                    0.73171
                                                   21
       true
               0.72727
                         0.76190
                                    0.74419
                                                   21
                                    0.73810
                                                   42
   accuracy
   macro avq
               0.73864
                          0.73810
                                    0.73795
                                                   42
weighted avg
               0.73864
                          0.73810
                                    0.73795
                                                   42
```

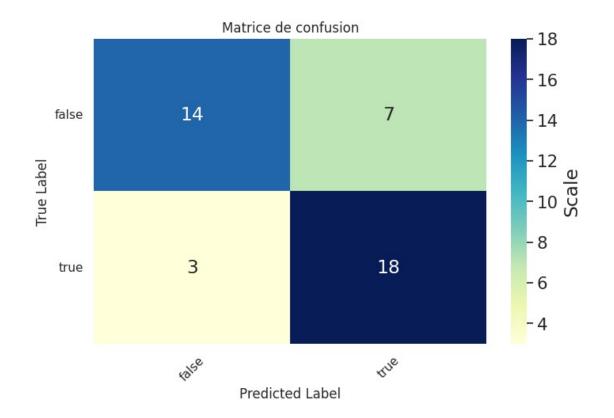


```
testMNB(X train, y train, 3, "./Data parametrage/data mnb mat 4 3")
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'mnb']
parameters :
{'cleaner removedigit': [True, False], 'cleaner getlemmatisation':
[True, False], 'tfidf__stop_words': ['english', None],
'tfidf__lowercase': [True, False], 'mnb__alpha': array([0.5, 0.7, 0.9,
1.1, 1.3, 1.5]), 'mnb fit prior': [True, False], 'mnb force alpha':
[True, False]}
Fitting 3 folds for each of 384 candidates, totalling 1152 fits
réalisé en 137.809 s
Meilleur résultat : 0.764
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: False
     cleaner removedigit: True
     mnb__alpha: 1.3
     mnb fit prior: True
     mnb__force_alpha: True
     tfidf lowercase: True
     tfidf stop words: 'english'
Les premiers résultats :
      cleaner getlemmatisation cleaner removedigit mnb alpha \
268
                         False
                                                True
                                                             1.3
                         False
                                                True
                                                             1.3
```

264

```
260
                         False
                                                 True
                                                              1.3
                         False
256
                                                 True
                                                              1.3
252
                         False
                                                 True
                                                              1.1
     mnb fit prior mnb force alpha tfidf lowercase
tfidf stop words \
268
              False
                                False
                                                    True
english
264
              False
                                 True
                                                    True
enalish
                                False
260
               True
                                                    True
english
256
               True
                                 True
                                                    True
english
252
              False
                                False
                                                    True
english
     accuracy
268
    0.764286
264 0.764286
260 0.764286
256 0.764286
252 0.761905
import pickle
from sklearn.naive bayes import MultinomialNB
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9 # 70% pour le jeu d'apprentissage, il reste 30% du jeu
de données pour
testsize= 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
train size=trainsize, random state=seed, test size=testsize, stratify=y t
rain)
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words='english')),
    ('mnb', MultinomialNB(alpha=1.3, fit prior=False,
force alpha=False))
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Mnb final 4 step3.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
```

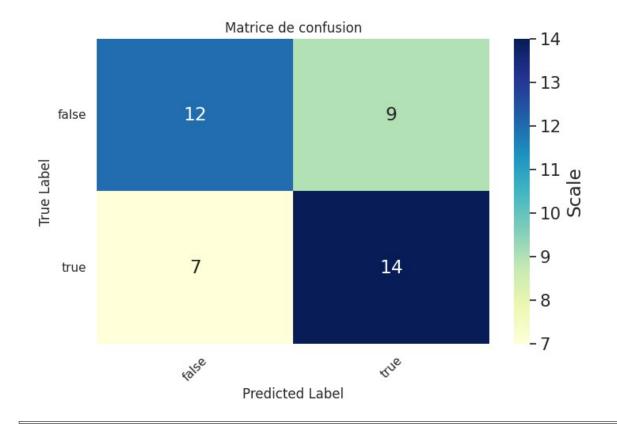
```
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test avec les données qu'il a apprise c'est parfait woahhha c'est
beau
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test_note,y_pred)
Sauvegarde du modèle dans ./Modele/final/Mnb final 4 step3.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer(removedigit=True)),
                ('tfidf', TfidfVectorizer(stop words='english')),
                ('mnb',
                 MultinomialNB(alpha=1.3, fit prior=False,
force alpha=False))])
Accuracy: 0.762
Classification Report
              precision
                           recall f1-score
                                              support
                0.82353
       false
                          0.66667
                                                   21
                                    0.73684
        true
                0.72000
                          0.85714
                                    0.78261
                                                   21
                                    0.76190
                                                   42
    accuracy
                0.77176
                          0.76190
                                    0.75973
                                                   42
   macro avg
                0.77176
                                    0.75973
                                                   42
weighted avg
                          0.76190
```



```
testRFC(X train, y train, 3, "./Data parametrage/data rfc mat 4 3")
Application de gridsearch ...
pipeline : ['cleaner', 'tfidf', 'rfc']
parameters :
{'cleaner removedigit': [True, False], 'cleaner getlemmatisation':
[True, False], 'tfidf__stop_words': ['english', None],
'tfidf_lowercase': [True, False], 'rfc_n_estimators': [500, 1200],
'rfc__max_depth': [25, 30], 'rfc__min_samples_split': [5, 10, 15],
'rfc__min_samples_leaf': [1, 2]}
Fitting 3 folds for each of 384 candidates, totalling 1152 fits
réalisé en 276.001 s
Meilleur résultat : 0.752
Ensemble des meilleurs paramètres :
     cleaner__getlemmatisation: True
     cleaner__removedigit: True
     rfc__max_depth: 25
     rfc min samples leaf: 1
     rfc__min_samples_split: 15
     rfc n estimators: 500
     tfidf lowercase: False
     tfidf stop words: 'english'
Les premiers résultats :
      cleaner getlemmatisation cleaner__removedigit rfc__max_depth
\
```

```
197
                         False
                                                 True
                                                                   25
18
                                                                   25
                          True
                                                 True
69
                          True
                                                 True
                                                                   30
21
                          True
                                                 True
                                                                   25
126
                          True
                                                False
                                                                   25
     rfc min samples leaf rfc min samples split rfc n estimators
197
                                                  5
                         1
                                                                  1200
18
                         1
                                                 15
                                                                   500
69
                         1
                                                 15
                                                                  1200
21
                         1
                                                 15
                                                                  1200
                         2
126
                                                  5
                                                                  1200
     tfidf lowercase tfidf stop words accuracy
197
                 True
                                   None
                                         0.752381
                False
                                english
                                         0.752381
18
69
                 True
                                   None
                                         0.752381
21
                 True
                                   None 0.750000
126
                False
                                english 0.747619
import pickle
from sklearn.ensemble import RandomForestClassifier
from sklearn.model selection import train test split
# Création d'un jeu d'apprentissage et de test
trainsize=0.9 # 70% pour le jeu d'apprentissage, il reste 30% du jeu
de données pour
testsize= 0.1
seed=30
train title, test title, train note, test note=train test split(X train, y
train_size=trainsize,random_state=seed,test_size=testsize,stratify=y_t
rain) # stratified = ves
## double classification a regarder
pipeline=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words=None)),
```

```
('rfc', RandomForestClassifier(max depth=25,min samples leaf=1,
min samples split=5, n estimators=1200))
pipeline.fit(train title,train note)
filename='./Modele/TruevsFalsevsMixturevsOther/Rfc final 4 step3.pkl'
print("Sauvegarde du modèle dans ", filename)
pickle.dump(pipeline, open(filename, "wb"))
print ("Chargement du modèle \n")
# le chargement se fait via la fonction load
clf loaded = pickle.load(open(filename, 'rb'))
# affichage du modèle sauvegardé
print (clf loaded)
# test avec les données qu'il a apprise c'est parfait woahhha c'est
y pred = clf loaded.predict(test title)
# autres mesures et matrice de confusion
MyshowAllScores(test note,y pred)
Sauvegarde du modèle dans ./Modele/final/Rfc final 4 step3.pkl
Chargement du modèle
Pipeline(steps=[('cleaner', TextNormalizer(removedigit=True)),
                ('tfidf', TfidfVectorizer()),
                ('rfc',
                 RandomForestClassifier(max depth=25,
min samples split=5,
                                        n estimators=1200))])
Accuracy: 0.619
Classification Report
                         recall f1-score
              precision
                                              support
       false
                0.63158
                          0.57143
                                    0.60000
                                                   21
                0.60870
                          0.66667
                                    0.63636
                                                   21
        true
                                    0.61905
                                                   42
    accuracy
             0.62014
                                                   42
                          0.61905
                                    0.61818
   macro avg
weighted avg
              0.62014
                          0.61905
                                    0.61818
                                                   42
```



## -> Etape 4 : mise en forme de la double classification

```
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.naive_bayes import MultinomialNB
from sklearn.ensemble import RandomForestClassifier

mySample = pd.read_csv('./Data_equilibre/MyData_Sprintlet2.csv',
sep=",")

mySample['notation'] = mySample['our rating']

for i in range(0,len(mySample['notation'])):
    if mySample['notation'][i] == 'false' or mySample['notation'][i]
== 'true':
        mySample['notation'][i] = 'false/true'
    if mySample['notation'][i] == 'other' or mySample['notation'][i]
== 'mixture':
        mySample['notation'][i] = 'other/mixture'
```

```
# print(mySample['notation'].value counts())
X train = mySample['text']
y train = mySample['notation']
z train = mySample['our rating']
trainsize=0.9
testsize= 0.1
seed=30
train title, test title, train note, test note, train rating, test rating=t
rain test split(X train, y train, z train,
train size=trainsize,random state=seed,test size=testsize,stratify=z t
rain)
new class data0 = pd.DataFrame(np.column_stack((train_title,
train_note,train_rating)), columns=['text','note','our rating'])
# on recupere le True et False dans classif1
classif1 = new class data0.loc[~new class data0['our
rating'].isin(["other","mixture"])]
# on recupere le Mixture et Other dans classif2
classif2 = new class data0.loc[~new class data0['our
rating'].isin(["true", "false"])]
# premièere classification
pipeline0=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words=None)),
    ('lr', LogisticRegression(C=100,penalty='l2', solver='newton-cg'))
])
pipeline0.fit(train title,train note)
# seconde classification pour True vs False
pipeline1=Pipeline([
    ("cleaner", TextNormalizer(removedigit=True,
getlemmatisation=False)),
    ("tfidf", TfidfVectorizer(lowercase=True, stop words='english')),
    ('mnb', MultinomialNB(alpha=1.3, fit prior=False,
force alpha=False))
1)
pipeline1.fit(classif1['text'],classif1['our rating'])
# seconde classification pour Mixture vs Other
pipeline2=Pipeline([
    ("cleaner", TextNormalizer(removedigit=False,
getlemmatisation=True)),
```

```
("tfidf", TfidfVectorizer(lowercase=True, stop words=None)),
    ('rfc', RandomForestClassifier(max depth=25,min samples leaf=2,
min samples split=15, n estimators=500))
1)
pipeline2.fit(classif2['text'],classif2['our rating'])
# test 0
y pred0 = pipeline0.predict(test title)
# MyshowAllScores(test note,y pred0)
predictions df = pd.DataFrame({'predictions': y pred0})
new class data = pd.DataFrame(np.column stack((test title,
y pred0,test note,test rating)), columns=['text',
predictions','note','our rating'])
# on recupere le True et False dans classif1
classif1 test =
new class data.loc[~new class data['predictions'].isin(['other/mixture
'])]
# on recupere le Mixture et Other dans classif2
classif2 test =
new class data.loc[~new class data['predictions'].isin(['false/true'])
# test 1
y pred1 = pipeline1.predict(classif1 test['text'])
# autres mesures et matrice de confusion
# MyshowAllScores(classif1 test['our rating'],y pred1)
classif1 test = classif1 test.assign(resultat=y pred1)
# test 2
y pred2 = pipeline2.predict(classif2 test['text'])
# autres mesures et matrice de confusion
# MyshowAllScores(classif2 test['our rating'],y pred2)
classif2 test = classif2 test.assign(resultat=y pred2)
data final = pd.concat([classif1 test,classif2 test], ignore index =
True)
```

```
MyshowAllScores(data final['our rating'],data final['resultat'])
```

<ipython-input-33-39e2c058e94e>:12: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation:

https://pandas.pydata.org/pandas-docs/stable/user\_guide/indexing.html#returning-a-view-versus-a-copy

mySample['notation'][i] = 'false/true'

<ipython-input-33-39e2c058e94e>:14: SettingWithCopyWarning:

A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation:

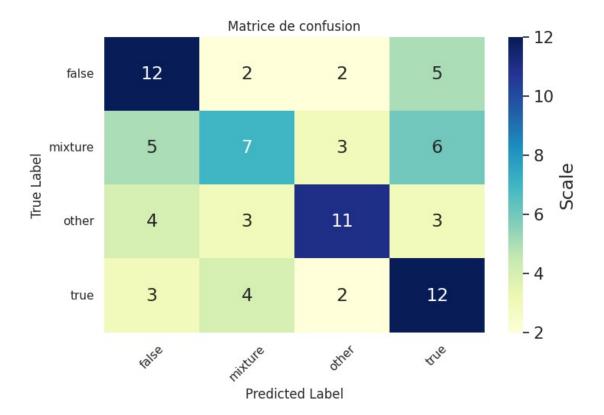
https://pandas.pydata.org/pandas-docs/stable/user\_guide/indexing.html#returning-a-view-versus-a-copy

mySample['notation'][i] = 'other/mixture'

Accuracy: 0.500

Classification Report

	precision	recall	f1-score	support
false mixture other true	0.50000 0.43750 0.61111 0.46154	0.57143 0.33333 0.52381 0.57143	0.53333 0.37838 0.56410 0.51064	21 21 21 21
accuracy macro avg weighted avg	0.50254 0.50254	0.50000 0.50000	0.50000 0.49661 0.49661	84 84 84



Malgré la double classification, les résultats ne sont pas à la hauteur de nos espérances. En effet même si pris séparément les modèles sont relativement correct, l'enchaînement des pipelines crée un effet d'accumulation des erreurs.